

Содержание

Введение	2
1 Теоретические основы прогнозирования финансовых временных рядов	7
1.1 Особенности финансовых временных рядов	7
1.2 Классические модели прогнозирования курса валют	9
1.3 Методы машинного обучения в прогнозировании	12
1.4 Нейросетевые модели прогнозирования	14
1.5 Обзор исследований по сравнению моделей прогнозирования	18
2 Методология исследования и описание данных	22
2.1 Выбор объекта исследования	22
2.2 Очистка и подготовка данных	25
2.3 Постановка задачи прогнозирования	27
2.4 Используемые модели	30
2.5 Обоснование выбора гиперпараметров моделей	31
3 Практическая реализация (эксперименты и результаты)	34
3.1 Результаты обучений классических моделей	34
3.2 Результаты ML-моделей	38
3.3 Построение и обучение LSTM	40
3.4 Сравнение результатов всех моделей	44
3.5 Интерпретация результатов	47
Заключение	51
Список литературы	54
Приложения	55

Введение

Актуальность темы. Современные финансовые рынки характеризуются высокой степенью нестабильности, представляя собой сложную, хаотичную и высокодинамичную среду. В условиях глобализации и непрерывных изменений экономических тенденций прогнозирование валютных курсов приобретает особую значимость. Точные прогнозы жизненно необходимы для макроэкономического планирования, стабильной работы банковского сектора, инвестиционной деятельности и эффективного государственного управления. Однако данная задача осложнена беспрецедентно высокой волатильностью и неполнотой рыночной информации. В отличие от многих других сфер (например, прогнозирования спроса на электроэнергию, где известны четкие факторы — погода или календарные дни), понимание факторов, влияющих на курсы валют, сильно ограничено, а структура валютного рынка такова, что распространение широко известных прогнозов способно влиять на поведение его участников, что дополнительно усложняет задачу. Традиционные методы прогнозирования далеко не всегда дают точные результаты и не способны уловить все закономерности в условиях хаоса. В последние годы, чтобы решить эту проблему, активно развиваются и внедряются алгоритмы машинного обучения (ML) и глубокие нейросети, предлагая новый взгляд на анализ данных. В научной литературе сформировалось два основных подхода к прогнозированию: использование классических статистических моделей и применение методов, основанных на данных, — от классических алгоритмов машинного обучения (например, Random Forest) до архитектур глубокого обучения (LSTM), которые могут демонстрировать существенно различную эффективность даже в рамках одной общей категории. Традиционно прогнозирование финансовых временных рядов осуществлялось с помощью классических моделей, флагманом среди которых является интегрированная модель авторегрессии и скользящего среднего (ARIMA). При всех своих плюсах, модели этого класса имеют существенное ограничение: они предполагают линейную форму взаимосвязей и зачастую постоянную дисперсию, из-за чего им трудно справляться с нелинейными рыночными паттернами [1; 2].

С другой стороны, искусственные нейронные сети и методы глубокого обучения, такие как сети с долгой краткосрочной памятью (LSTM), обладают высочайшей гибкостью и мощным потенциалом для нелинейного моделирования. Архитектуры LSTM способны сохранять важную информацию из более ранних периодов благодаря специальным механизмам памяти, что делает их крайне эффективными для временных рядов. Однако проблема заключается в том, что в научном сообществе до сих пор нет однозначного ответа, какой метод лучше. Несмотря на наличие большого количества исследований, результаты остаются противоречивыми: одни работы доказывают подавляющее превосходство нейросетей [3; 4], тогда как другие указывают, что классические методы или гибридные модели показывают не менее высокую, а порой и лучшую точность [5].

Степень разработанности проблемы. Прогнозирование финансовых временных рядов является одним из активно развивающихся направлений эконометрики и анализа данных. Теоретические основы прогнозирования временных рядов были заложены в работах Дж. Бокса и Г. Дженкинса [7], Дж. Гамильтона [6], У. Эндерса [2] и других исследователей. В последние годы наряду с классическими статистическими методами широкое распространение получили методы машинного обучения и нейросетевые модели, в частности Random Forest и LSTM. Несмотря на значительное количество исследований в данной области, вопрос выбора наиболее эффективного подхода для прогнозирования финансовых показателей остается актуальным и требует дальнейшего изучения.

Научная новизна исследования. Научная новизна исследования заключается в сравнительном анализе классической статистической модели (ARIMA), классического алгоритма машинного обучения (Random Forest) и архитектуры глубокого обучения (LSTM) для прогнозирования курса USD/UZS на данных, охватывающих период после валютной либерализации Узбекистана (с 5 сентября 2017 года), когда курс национальной валюты впервые начал формироваться на основе рыночных механизмов. В отличие от большинства исследований, выполненных на данных стабильных и давно сформировавшихся валютных рынков, в настоящей работе модели оцениваются на ряде, характеризующемся структурным сдвигом и переходным режимом курсообразования, что позволяет проверить устойчивость рассмат-

риваемых методов в условиях формирующегося рынка. Использование единых критериев качества (MAE, MSE, RMSE, MAPE) и единой методологии предобработки данных обеспечивает сопоставимость результатов между моделями.

Цель работы. Целью данной работы является сравнительный анализ эффективности классической статистической модели (ARIMA), классического алгоритма машинного обучения (Random Forest) и архитектуры глубокого обучения (LSTM) при прогнозировании курса валют.

Задачи работы. Для достижения поставленной цели были сформулированы следующие задачи:

1. анализ и систематизация теоретических основ моделирования финансовых временных рядов и специфики функционирования валютного рынка;
2. математическое и алгоритмическое обоснование применения параметрических методов, алгоритмов машинного обучения и архитектур глубокого обучения для задач краткосрочного прогнозирования;
3. разработка комплексной методики сбора, очистки и предобработки исторических данных динамики валютного курса;
4. программная реализация, адаптация и обучение прогнозных моделей ARIMA, Random Forest и LSTM на сформированных выборках;
5. проведение сравнительного анализа прогностической точности построенных моделей на основе комплекса статистических метрик (MAE, MSE, RMSE, MAPE) и интерпретация полученных результатов.

Объект исследования. Объектом исследования выступает динамика валютного курса (на примере валютной пары USD/UZS) в условиях формирующегося рынка.

Предмет исследования. Предметом исследования являются закономерности, математические модели и алгоритмы краткосрочного прогнозирования временного ряда курса USD/UZS.

Практическая значимость исследования. Практическая значимость исследования заключается в том, что полученные результаты и разработанная методика построения прогнозов могут быть использованы Центральным

банком Республики Узбекистан и коммерческими банками при краткосрочном прогнозировании курса USD/UZS, а также субъектами внешнеэкономической деятельности при планировании валютных операций и оценке курсовых рисков. Реализованный программный инструментарий, включающий методику предобработки данных, обучения моделей ARIMA, Random Forest и LSTM и сопоставления их прогностической точности, может быть использован в учебном процессе при изучении дисциплин, связанных с эконометрикой и анализом финансовых временных рядов, а также в дальнейших научных исследованиях в данной области.

Апробация и внедрение результатов. Основные положения и результаты выпускной квалификационной работы были представлены и обсуждены на Республиканской научной конференции молодых ученых «Актуальные проблемы и приложения современной математики» (г. Ташкент, 13–14 марта 2026 г.). По результатам предварительного этапа исследования опубликованы тезисы доклада на тему «Модели ARIMA и методы сглаживания для анализа финансовых временных рядов», в которых были рассмотрены отдельные вопросы построения базовой статистической модели, легшей в основу последующего сравнительного анализа с методами машинного обучения, представленного в настоящей работе.

Методы исследования. В процессе выполнения работы применяются следующие методы анализа и прогнозирования:

1. статистические методы (в частности, параметрические модели ARIMA);
2. методы машинного обучения (ML);
3. нейросетевые методы (включая архитектуру рекуррентных сетей LSTM).

Структура работы. Работа состоит из введения, трёх глав, заключения, списка литературы и приложений. В первой главе изложены теоретические основы прогнозирования финансовых временных рядов: их особенности, классические статистические модели, методы машинного обучения и нейросетевые архитектуры. Вторая глава посвящена методологии и данным: обоснованию выбора пары USD/UZS, подготовке исторических данных, по-

становке задачи и описанию используемых моделей. В третьей главе приведены результаты обучения классических, ML и LSTM-моделей, их сравнение по метрикам качества и интерпретация. В заключении обобщены итоги и сформулированы выводы, в приложениях — фрагменты кода и дополнительные материалы.

Глава 1. Теоретические основы прогнозирования финансовых временных рядов

1.1 Особенности финансовых временных рядов

Временным рядом (или рядом динамики) называется последовательность значений некоторого статистического показателя (случайной величины), упорядоченных в хронологическом порядке [6; 15] — в последовательные моменты или периоды времени. В экономике и финансах типичными примерами временных рядов выступают курсы обмена валют, котировки акций, уровень инфляции, показатели спроса и валовой национальный продукт. В зависимости от характера фиксации времени ряды могут быть дискретными и непрерывными. В непрерывных рядах значения переменной фиксируются непрерывно во времени, однако на практике (особенно в финансах) чаще всего анализируются дискретные временные ряды, где наблюдения производятся через определенные фиксированные интервалы времени (например, ежечасно, ежедневно, ежемесячно). Таким образом, временной ряд в контексте данной работы — это упорядоченная во времени последовательность исторических значений валютного курса.

В классическом анализе любой экономический временной ряд традиционно рассматривается как результат взаимодействия нескольких основных компонент:

- Тренд (тенденция) — плавно меняющаяся компонента, описывающая чистое влияние долговременных факторов и отражающая общую (вековую) тенденцию процесса к росту или снижению.
- Сезонность — регулярные колебания, отражающие внутригодовую или внутримесячную повторяемость экономических процессов.
- Цикличность — последовательность волнообразных флуктуаций (экономических циклов), длительность которых обычно превышает один год (например, циклы деловой активности).
- Случайная (нерегулярная) составляющая (шум) — непредсказуемые колебания, отражающие влияние множества не поддающихся учету

случайных факторов.

Ключевым свойством, необходимым для анализа и моделирования, является стационарность временного ряда. Строго стационарным называется ряд, совместное распределение вероятностей которого не изменяется при сдвиге во времени. В практических исследованиях чаще опираются на понятие слабой стационарности: ряд считается стационарным, если его математическое ожидание (среднее значение) и дисперсия остаются постоянными во времени, а ковариация зависит только от временного лага [16].

Стационарность крайне важна, поскольку большинство классических статистических методов и теорем опираются на предположение о неизменности свойств процесса. Проблема заключается в том, что реальные финансовые ряды практически всегда нестационарны. Их среднее значение и дисперсия меняются с течением времени, формируя стохастические тренды. Для приведения таких рядов к стационарному виду обычно применяются математические преобразования, чаще всего — переход от абсолютных значений к их разностям (приращениям).

Финансовые временные ряды, в частности курсы валют, обладают ярко выраженной спецификой, которая значительно усложняет их математическое описание:

- **Волатильность.** Для финансовых рынков характерны резкие скачки и нестабильность дисперсии. Широко известен эффект «кластеризации волатильности»: периоды сильных и резких колебаний цены часто сменяются периодами относительного затишья [19; 25].
- **Нестационарность.** Валютные курсы подвержены влиянию макроэкономических трендов и структурных изменений. Часто их поведение близко к процессу «случайного блуждания» (random walk), что делает их непредсказуемыми на больших горизонтах [24].
- **Автокорреляция.** Текущие значения финансовых показателей и их волатильность часто зависят от прошлых значений (наличие "памяти" у рынка), что фиксируется с помощью автокорреляционных функций.
- **Нелинейность.** Динамика финансовых рынков характеризуется высокой сложностью, а поведение участников рынка приводит к тому, что

изменения цен не описываются простыми линейными формулами.

- Шум и случайность. Финансовые показатели содержат значительную долю шума (соотношение сигнал/шум крайне низкое). На них ежеминутно влияют поступление новых случайных новостей, макроэкономическая статистика и политические события [20].

Специфические свойства финансовых временных рядов порождают серьезные трудности при их прогнозировании. Из-за беспрецедентно высокой неопределенности, динамизма и хаотичности финансовой среды предсказание курсов валют является задачей повышенной сложности. Традиционные статистические подходы и линейные модели (такие как ARIMA или экспоненциальное сглаживание), несмотря на их полезность, не всегда справляются с нелинейной природой и высокой зашумленностью финансовых данных. Это обуславливает необходимость использования более сложных и гибких аналитических инструментов.

Финансовые временные ряды представляют собой сложные, хаотичные и нестационарные структуры. Присущие им специфические свойства — высокая волатильность, нелинейность, подверженность случайным шокам и структурным сдвигам — требуют для анализа и точного прогнозирования применения современных продвинутых методов, в том числе алгоритмов машинного обучения и нейронных сетей.

1.2 Классические модели прогнозирования курса валют

Классические (статистические) методы прогнозирования основаны на математическом и статистическом анализе исторических данных временных рядов. На протяжении долгого времени они оставались основными и де-факто стандартными инструментами прогнозирования в экономике, финансах и бизнес-аналитике. Их доминирование было обусловлено хорошо проработанной теоретической базой и способностью выявлять базовые закономерности в данных задолго до появления современных вычислительных мощностей [17; 18].

Самые простые подходы к прогнозированию опираются на методы усреднения прошлых наблюдений для выделения основной тенденции.

- Простое скользящее среднее (Moving Average): Идея этого метода за-

ключается в вычислении среднего значения ряда за определенное фиксированное "окно" времени в прошлом. Это позволяет сгладить случайные колебания и шум в данных. Однако существенным минусом скользящего среднего является его запаздывание: прогнозы на основе этого метода всегда отстают от реальных изменений тренда.

- Экспоненциальное сглаживание: Данный метод решает проблему простого усреднения путем присвоения прошлым значениям различных весовых коэффициентов. Веса экспоненциально убывают по мере "старения" данных, благодаря чему наибольший вес придается самым последним наблюдениям. Это позволяет модели гораздо лучше и быстрее реагировать на недавние изменения курса.

Этот блок моделей формирует фундаментальную основу для анализа внутренней структуры временного ряда.

- AR (Autoregression — Авторегрессия): В моделях AR текущее значение переменной описывается как линейная зависимость от её собственных прошлых значений. Например, текущий курс валюты прогнозируется на основе курсов за вчерашний, позавчерашний и несколько предыдущих дней.
- MA (Moving Average — Скользящее среднее): В контексте статистического моделирования модель MA устанавливает зависимость текущего значения не от самих прошлых курсов, а от прошлых ошибок прогноза (случайных шоков или возмущений).
- ARMA (Autoregressive Moving Average): Представляет собой комбинацию авторегрессии (AR) и скользящего среднего (MA). Эта модель является базовой, но имеет жесткое ограничение: она корректно работает только для стационарных временных рядов.

Поскольку подавляющее большинство финансовых рядов нестационарны, центральной классической моделью стала ARIMA (Autoregressive Integrated Moving Average) [7]. Модель характеризуется тремя параметрами — $ARIMA(p, d, q)$, где p — порядок авторегрессии, d — порядок дифференциации, q — порядок скользящего среднего.

Ключевым нововведением является параметр дифференциации d (Integrated). Чтобы применить модель к нестационарному курсу валют, алгоритм ARIMA сначала вычисляет разности между текущими и предыдущими значениями. Взятие разностей позволяет устранить тренд и сделать ряд стационарным. После дифференциации к преобразованному ряду $w_t = \Delta^d y_t$ применяется модель ARMA(p, q), которая описывается формулой:

$$w_t = c + \sum_{i=1}^p \phi_i w_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t,$$

где c — константа, ϕ_i — коэффициенты авторегрессии, θ_j — коэффициенты скользящего среднего, ε_t — белый шум (случайная ошибка).

Благодаря своей универсальности, ARIMA стала классическим стандартом прогнозирования в экономике и финансах.

Для учета дополнительных факторов классические модели были расширены:

- SARIMA: Данная модификация классической модели ARIMA учитывает сезонность. Она эффективна, если внутри временного ряда присутствуют регулярные циклические колебания (например, квартальные или месячные эффекты).
- ARIMAX: Позволяет включать в уравнение внешние независимые факторы (экзогенные переменные). Это дает возможность прогнозировать курс валюты не только по его собственной истории, но и с учетом внешних макроэкономических показателей.

Основными достоинствами классических статистических методов являются их простота и высокая интерпретируемость. Исследователь всегда может отследить логику модели и оценить статистическую значимость каждого коэффициента. Эти методы базируются на хорошо проверенной математической теории, что делает их результаты понятными и обоснованными.

Несмотря на статус рыночного стандарта, классические модели обладают существенными ограничениями. Главная проблема заключается в том, что они предполагают исключительно линейную форму взаимосвязи между переменными. В реальности же динамика валютных рынков имеет сложную нелинейную природу, которую эти модели не способны уловить. Кроме того,

они строго требуют стационарности (или приведения к ней) и обладают слабой способностью адаптироваться к структурным изменениям, что выливается в ограниченную точность прогнозирования в периоды рыночных шоков.

Таким образом, признавая модели семейства ARIMA надежной теоретической базой для анализа временных рядов, их неспособность эффективно обрабатывать сложную нелинейность финансовых рынков обуславливает объективную необходимость перехода к передовым методам машинного обучения и нейронным сетям.

1.3 Методы машинного обучения в прогнозировании

Методы машинного обучения (ML) [8; 9] представляют собой подходы, позволяющие компьютерным моделям самостоятельно выявлять скрытые закономерности и извлекать знания непосредственно из «сырых» данных, без необходимости явного программирования жестких правил. В отличие от классических статистических моделей, алгоритмы машинного обучения не требуют строгих предварительных предположений (например, о нормальности распределения ошибок или линейности связей) и обладают способностью адаптировать свои параметры к сложным структурам в процессе обучения на исторических данных (обучающей выборке).

Применение методов машинного обучения к анализу временных рядов имеет принципиальную особенность: в своей базовой форме стандартные ML-алгоритмы не «понимают» природу времени, воспринимая набор данных как неупорядоченную совокупность независимых примеров. Для того чтобы алгоритм смог уловить динамику курса валют, данные необходимо специфическим образом преобразовать.

Чаще всего для этого используется метод скользящего окна, при котором создаются лаговые переменные (lags). В этом случае для прогнозирования текущего значения курса $y(t)$ в качестве входных признаков подаются его предыдущие исторические значения: $y(t-1)$, $y(t-2)$, $y(t-3)$ и так далее. Помимо этого, критически важными этапами становятся ручное конструирование признаков (feature engineering) и строгая нормализация данных, которая приводит значения к единому масштабу и обеспечивает корректную работу алгоритмов.

В современной аналитике используется ряд базовых и продвинутых

ML-алгоритмов:

- **Линейная регрессия.** Простая параметрическая модель, предполагающая строгую линейную зависимость между входными лагами и прогнозируемым значением. Несмотря на свою ограниченность, она обладает прозрачной математической структурой и часто используется в качестве базового уровня (benchmark) для оценки качества более сложных методов.
- **Деревья решений (Decision Trees).** Непараметрический метод (например, алгоритм CART), который последовательно разбивает пространство входных признаков на набор непересекающихся областей с помощью простых логических условий. Деревья способны улавливать нелинейные зависимости, однако в чистом виде они весьма нестабильны и склонны к сильному переобучению.
- **Случайный лес (Random Forest) [10].** Мощный ансамблевый метод, объединяющий множество независимых деревьев решений. Обучаясь на случайных подвыборках данных (bagging) и используя лишь случайное подмножество признаков для каждого разбиения, случайный лес декоррелирует деревья. Это значительно снижает общую дисперсию модели, повышает ее устойчивость к шуму и улучшает точность прогноза.
- **Градиентный бустинг (Gradient Boosting).** Еще один ансамблевый подход, в котором деревья строятся не независимо, а последовательно. Каждое новое дерево обучается на остатках (ошибках) предыдущего, тем самым алгоритм «медленно» и целенаправленно улучшает предсказательную способность. Современные реализации этого метода (например, XGBoost или LightGBM) обеспечивают высочайшую точность и крайне популярны в практических задачах.

Ключевым преимуществом методов машинного обучения является их способность эффективно выявлять и моделировать сложные нелинейные взаимосвязи между переменными. В отличие от классической эконометрики, ML-алгоритмы обладают высокой гибкостью, не требуют строгой стационарности ряда на этапе моделирования и демонстрируют значительно более вы-

сокую точность на больших массивах зашумленных данных. Благодаря этому в сфере прогнозирования валютных курсов методы машинного обучения нашли широчайшее применение. Они активно внедряются в системы финансовой аналитики и алгоритмического трейдинга для оценки трендов, поскольку способны учитывать сложные перекрестные зависимости.

Несмотря на высокую результативность, методы ML имеют ряд существенных ограничений. Во-первых, они критически зависят от качества ручного конструирования признаков. Во-вторых, высокые модели (особенно деревья и ансамбли) подвержены риску переобучения (overfitting), когда алгоритм запоминает случайный шум вместо выявления истинных трендов. В-третьих, по мере роста сложности значительно ухудшается интерпретируемость моделей, превращая их в «черный ящик».

Однако главная проблема состоит в том, что традиционные методы машинного обучения не учитывают внутреннюю временную последовательность данных так же органично и глубоко, как это делают специализированные рекуррентные нейросети. Ограничения ML-моделей при работе со сложными последовательностями обуславливают необходимость перехода к современным нейросетевым архитектурам глубокого обучения, способным самостоятельно анализировать временной контекст.

1.4 Нейросетевые модели прогнозирования

Нейронные сети представляют собой вычислительные модели, способные выявлять сложные нелинейные зависимости в данных. Изначально концепция искусственных нейронных сетей была вдохновлена попытками исследователей математически описать процессы обработки информации в биологических нервных системах и мозге человека. Однако сегодня, в контексте практического машинного обучения и прогнозирования, они используются в первую очередь как эффективный инструмент статистического распознавания образов и мощный аппроксиматор функций. Главная ценность нейросетей заключается в их способности самостоятельно извлекать скрытые правила и паттерны из «сырых» данных, решая задачи, с которыми традиционные алгоритмы не справляются.

В своей базовой форме архитектура нейронной сети состоит из нескольких слоев обработки информации. Традиционная структура включа-

ет:

- входной слой (принимает исходные данные);
- один или несколько скрытых слоев (выполняют основную вычислительную работу);
- выходной слой (выдает итоговый результат или прогноз).

Эти слои состоят из множества узлов (искусственных нейронов). Нейроны соседних слоев соединены между собой связями, каждая из которых имеет свой вес — числовой параметр, определяющий силу влияния одного узла на другой. Кроме того, каждый нейрон в скрытых слоях использует функцию активации — специальное математическое преобразование, которое добавляет в систему нелинейность. Именно наличие функции активации позволяет нейронной сети строить сложные кривые и улавливать нелинейные эффекты, а не просто сводиться к простой линейной модели.

Обучение нейронной сети — это итеративный процесс, при котором сеть подбирает оптимальные веса для минимизации ошибки. Для оценки качества работы сети используется функция потерь (ошибка), измеряющая разницу между предсказанием модели и фактическим значением. Обучение осуществляется с помощью алгоритма обратного распространения ошибки (backpropagation). Суть алгоритма в том, что он вычисляет долю ответственности каждого параметра за итоговую ошибку и передает этот сигнал ошибки в обратном направлении — от выходного слоя к входному, последовательно корректируя веса так, чтобы на следующем шаге прогноз стал точнее.

Благодаря своей высокой гибкости нейросети стали применяться для анализа финансовых временных рядов. Они способны эффективно учитывать сложнейшие перекрестные зависимости, работать с зашумленными нелинейными данными и адаптироваться к изменяющимся условиям рынка. Однако обычные сети прямого распространения имеют существенный недостаток: они обрабатывают каждый пример изолированно и плохо учитывают саму хронологическую последовательность данных (отсутствие "памяти"), что критично для временных рядов.

Для того чтобы сеть могла улавливать временную динамику, были разработаны рекуррентные нейронные сети (RNN). В отличие от сетей прямого

распространения, архитектура RNN содержит обратные связи (циклы), что позволяет им сохранять информацию о прошлых состояниях и использовать предыдущие значения для прогнозирования текущих. Это делает их естественно приспособленными для работы со временем.

Ключевая проблема стандартных RNN заключается в так называемом «затухании градиентов» (vanishing gradients). При попытке обучить сеть улавливать зависимости между событиями, далеко разнесенными во времени, сигнал ошибки экспоненциально уменьшается в процессе обратного распространения, из-за чего сеть на практике способна «помнить» лишь небольшое количество последних шагов.

Сеть с долгой краткосрочной памятью (Long Short-Term Memory, LSTM) [11] представляет собой глубоко улучшенную версию RNN, специально спроектированную для решения проблемы затухающих градиентов. Эта архитектура умеет стабильно «запоминать» долгосрочные зависимости на протяжении больших отрезков времени. За счет поддержания постоянного потока ошибки во времени, LSTM успешно обходит ограничения простых RNN. На сегодняшний день она является одной из самых мощных моделей для работы со сложными временными рядами, включая финансовые котировки. Успех LSTM основан на том, что вместо обычных скрытых узлов в ней используются сложные «ячейки памяти». Поток информации в этих ячейках контролируется через три типа шлюзов («ворот»), математически описываемых следующим образом.

Забывающие ворота (forget gate) определяют, какую часть информации из предыдущего состояния ячейки следует «забыть»:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f),$$

где σ — сигмоидная функция активации, W_f — матрица весов, h_{t-1} — скрытое состояние на предыдущем шаге, x_t — текущий входной вектор, b_f — вектор смещения.

Входные ворота (input gate) решают, какую новую информацию следует добавить в состояние ячейки:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i), \quad \tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C).$$

На основе этих значений обновляется состояние ячейки памяти:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t,$$

где $\odot$ обозначает поэлементное умножение (произведение Адамара).

Выходные ворота (output gate) контролируют, какая часть информации из ячейки будет использована для формирования скрытого состояния:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o), \quad h_t = o_t \odot \tanh(C_t).$$

Такая логика позволяет сети избирательно управлять своей памятью.

К главным преимуществам нейросетевых моделей (и LSTM в частности) относятся:

- высочайшая точность прогнозирования при наличии достаточного объема данных;
- способность органично работать с сильной нелинейностью;
- автоматическое выявление сложнейших и неочевидных скрытых зависимостей без необходимости вручную задавать математическую формулу связи.

Тем не менее, применение нейросетей сопряжено с серьезными трудностями:

- высокая архитектурная и вычислительная сложность;
- алгоритмы требуют очень больших объемов размеченных исторических данных;
- модели долго обучаются и подвержены риску переобучения (overfitting);
- нейросети являются «чёрным ящиком»: их внутреннюю логику и причины конкретного предсказания практически невозможно интерпретировать.

Несмотря на перечисленные ограничения, глубокие нейросети, особенно архитектура LSTM, активно используются в финансах. Они дают отличные практические результаты в банковском секторе и биржевой аналитике, являясь передовым инструментом для прогнозирования сложных и волатильных валютных рядов, динамику которых не могут объяснить классические эконометрические методы.

Нейронные сети, и в особенности рекуррентные сети, представляют собой чрезвычайно мощный инструмент для анализа данных. Учитывая специфику финансовых рынков, модель LSTM является наиболее подходящей и эффективной среди нейросетевых архитектур для поставленной задачи. Именно эта модель будет использоваться в практической части дипломной работы для сравнения с классическими статистическими методами.

1.5 Обзор исследований по сравнению моделей прогнозирования

Вопрос о том, какой класс моделей — классические статистические или нейросетевые — обеспечивает более высокую точность прогнозирования финансовых временных рядов, остаётся одним из наиболее дискуссионных в литературе. За последние два десятилетия накоплен значительный объём эмпирических исследований, однако их результаты нельзя назвать однозначными: вывод о превосходстве того или иного подхода существенно зависит от типа данных, горизонта прогнозирования, объёма обучающей выборки и способа постановки эксперимента. В данном разделе рассматриваются ключевые работы, посвящённые прямому сравнению моделей семейства ARIMA с нейросетевыми архитектурами, а также обобщаются полученные в них выводы.

Фундамент классического подхода к анализу временных рядов был заложен в работах Бокса и Дженкинса, предложивших методологию построения моделей авторегрессии — проинтегрированного скользящего среднего (ARIMA) и формализовавших процедуру идентификации, оценивания и диагностики таких моделей [7]. Развитие этой методологии применительно к экономическим и финансовым данным подробно описано в фундаментальных трудах по эконометрике временных рядов [2; 6], где показано, что модели класса ARIMA хорошо описывают линейные зависимости и краткосрочную динамику стационарных (или приводимых к стационарным) рядов. Со-

временное практико-ориентированное изложение принципов прогнозирования, включая критерии выбора модели и методы оценки качества прогноза, представлено в работе Хайндмана и Атанасопулоса [14]. Вместе с тем все эти источники сходятся в том, что главным ограничением классических моделей является предположение о линейности связей, из-за чего они плохо улавливают нелинейные эффекты, характерные для финансовых рынков.

Стремление преодолеть это ограничение привело к появлению гибридных и нейросетевых подходов. Одной из наиболее цитируемых работ в этой области стала статья Чжана [1], в которой предложена гибридная модель, объединяющая ARIMA и искусственную нейронную сеть. Идея метода состоит в том, что ARIMA моделирует линейную составляющую ряда, а нейронная сеть обучается на остатках, улавливая оставшуюся нелинейную компоненту. На примере нескольких классических наборов данных автор показал, что такая гибридная схема даёт более точные прогнозы, чем каждая из моделей по отдельности. Этот результат стал важным аргументом в пользу того, что линейные и нелинейные методы не столько конкурируют, сколько дополняют друг друга.

С развитием рекуррентных нейронных сетей и, в частности, архитектуры долгой краткосрочной памяти (LSTM) [11], фокус исследований сместился к прямому сравнению ARIMA и глубоких моделей. Наиболее показательной в этом отношении является работа Сиами-Намини и соавторов [3], в которой ARIMA и LSTM сравнивались на широком наборе экономических и финансовых временных рядов. Авторы пришли к выводу, что LSTM существенно превосходит ARIMA по точности: средняя ошибка прогноза снижалась на значительную величину (порядка восьмидесяти процентов по показателю среднеквадратичной ошибки) при переходе от классической модели к нейросетевой. Этот результат часто приводится как одно из наиболее весомых эмпирических свидетельств преимущества глубокого обучения в задачах прогнозирования финансовых рядов.

Применение LSTM непосредственно к биржевым данным исследовано в работе Нельсона и соавторов [4], где сеть использовалась для прогнозирования направления движения цен акций. Авторы показали, что LSTM позволяет получать точность предсказания направления, заметно превышающую уровень случайного угадывания, и устойчиво превосходит ряд базовых ме-

тодов. При этом подчёркивается, что качество прогноза сильно зависит от выбора входных признаков и горизонта прогнозирования, а сама задача предсказания направления движения цен остаётся крайне сложной из-за высокой зашумлённости финансовых данных.

Параллельно с нейросетевыми методами в задачах прогнозирования активно применяются ансамблевые алгоритмы машинного обучения, прежде всего случайный лес (Random Forest), предложенный Брейманом [10]. Случайный лес строит множество решающих деревьев на различных подвыборках данных и признаков и усредняет их прогнозы, что снижает дисперсию и риск переобучения. Применительно к временным рядам этот метод используется в режиме обучения с признаками-лагами: будущее значение прогнозируется по набору предшествующих наблюдений. Систематическое изложение методов статистического обучения, включая ансамблевые модели и принципы оценки их обобщающей способности, приведено в работе Джеймса и соавторов [13]. Случайный лес занимает промежуточное положение между классическими статистическими моделями и нейросетями: он способен улавливать нелинейные зависимости, но, в отличие от LSTM, не учитывает порядок наблюдений явным образом.

Обобщая результаты рассмотренных работ, можно выделить несколько закономерностей. Во-первых, превосходство нейросетевых моделей над классическими наиболее отчётливо проявляется на больших объёмах данных и при наличии выраженной нелинейности; при коротких рядах или преимущественно линейной динамике классические модели нередко не уступают, а иногда и превосходят нейросети. Во-вторых, результат сравнения критически зависит от методологии эксперимента — в частности, от того, обучаются ли модели один раз или переобучаются на каждом шаге прогнозирования (rolling forecast), что напрямую влияет на корректность интерпретации полученных метрик. В-третьих, всё большее распространение получают гибридные схемы, объединяющие сильные стороны разных подходов. Наконец, отдельный интерес представляют исследования, выполненные на данных развивающихся рынков. В частности, изучению специфики таких процессов посвящены работы, рассматривающие модели ARIMA и методы сглаживания для анализа финансовых временных рядов, в том числе в контексте макроэкономических показателей Республики Узбекистан [26].

Проведённый обзор показывает, что в научном сообществе отсутствует консенсус относительно безусловного превосходства какого-либо одного класса моделей, а корректное сравнение требует единых условий эксперимента и тщательного выбора метрик. Это обстоятельство определяет постановку задачи настоящей работы: провести сравнение классических статистических и нейросетевых моделей на едином наборе данных (валютная пара USD/UZS) с явным разграничением условий обучения, что позволяет сделать сопоставление методологически корректным.

Глава 2. Методология исследования и описание данных

2.1 Выбор объекта исследования

В качестве объекта исследования в данной дипломной работе выбран официальный курс доллара США к узбекскому суму (валютная пара USD/UZS) за период с 1 января 2015 года по 31 декабря 2025 года. Данный показатель представляет собой классический финансовый временной ряд исторических значений валютного курса, строго упорядоченных в хронологической последовательности. Прогнозирование именно этой финансовой метрики является центральной прикладной задачей для последующего применения и сравнения классических статистических алгоритмов и методов глубокого обучения.

Выбор курса USD/UZS в качестве основного объекта моделирования обусловлен высокой макроэкономической значимостью данного валютного курса для экономики Республики Узбекистан. Доллар США традиционно выступает ключевой резервной, инвестиционной и расчетной валютой. В условиях открытой экономики динамика курса доллара оказывает прямое и масштабное влияние на уровень внутренней инфляции, стоимость потребительской корзины, конкурентоспособность национального экспорта и объемы импортных операций. Точный прогноз данного показателя широко используется и крайне востребован в банковской сфере, государственном макроэкономическом планировании, корпоративном секторе и инвестиционном анализе для минимизации валютных рисков. Кроме того, выбор подкреплен наличием обширных, регулярно фиксируемых исторических данных, что является обязательным требованием для качественного и глубокого обучения нейросетевых моделей.

Критически важным аспектом любого математического и нейросетевого моделирования является использование достоверных, точных и согласованных эмпирических данных. В рамках данного исследования исторические данные получены из открытых официальных источников — базы данных Центрального банка Республики Узбекистан [12]. Использование официального курса гарантирует высокую степень надежности исходной информации. Выгруженный массив данных представлен в универсальном таблич-

ном формате CSV (Comma-Separated Values), который является стандартом для хранения структурированных данных и позволяет осуществлять быструю программную обработку (импорт, парсинг и очистку) средствами языков программирования (например, Python) на последующих этапах работы. Полный набор данных, использованных в исследовании, доступен в электронном виде в репозитории: <https://github.com/fuwe7/diploma>.

Сформированный исходный набор данных представляет собой дискретный одномерный временной ряд ежедневной частоты фиксации. Общая выборка охватывает 4018 последовательных наблюдений (календарных дней). Важнейшей позитивной характеристикой данного временного ряда является его строгая упорядоченность по времени и полное отсутствие пропусков (missing values) на всем рассматриваемом интервале. Это обстоятельство позволяет избежать применения искусственных методов интерполяции данных, которые потенциально могли бы исказить дисперсию ряда, внести нежелательный статистический шум в обучающую выборку и тем самым снизить объективность сравнения моделей.

Для первичного визуального анализа динамики валютной пары был построен линейный график исторического временного ряда.




Рис. 2.1: Динамика курса доллара США к узбекскому суму за 2015–2025 гг.

На представленном рисунке наглядно отображена траектория изменения курса доллара США к узбекскому суму. В целом, временной ряд имеет ярко выраженный долгосрочный восходящий тренд (девальвационная дина-

мика национальной валюты), на который накладываются периоды локальной стабилизации и стохастических колебаний. Однако при анализе графика особое внимание привлекает одна критическая аномалия — беспрецедентно резкий структурный скачок (изменение базового уровня курса), произошедший в начале сентября 2017 года. В этот короткий промежуток времени номинальное значение курса одномоментно выросло почти в два раза: с отметки около 4210 сумов до 8100 сумов за один доллар США.

Наличие столь радикального структурного сдвига на графике объясняется фундаментальными изменениями в экономике — проведением масштабной либерализации валютной политики и переходом Республики Узбекистан к рыночному механизму формирования курса (свободному плаванию). С точки зрения математической статистики и эконометрики, одним из важнейших условий сопоставимости уровней временного ряда является однородность этапов, в пределах которых исследуемый показатель подчиняется единому закону развития. В статистическом анализе для этого применяется исторический метод периодизации, согласно которому ряд необходимо разделять на однокачественные периоды на основе дат кардинальной смены хозяйственного механизма или принятия важнейших управленческих решений.

Если проводить обучение классических моделей и нейронных сетей на всем массиве данных с 2015 года, алгоритмы столкнутся с экстремальной неоднородностью (гетерогенностью) обучающей выборки. Модели будут пытаться математически аппроксимировать этот нерыночный структурный разрыв, что неизбежно приведет к смещению весов, искажению параметров тренда и критическому падению точности предсказаний на современном этапе. В связи с этим дальнейший анализ, стандартизация данных и непосредственное обучение моделей будут проводиться исключительно на однородной части массива — на данных, начиная с сентября 2017 года, когда сформировался современный рыночный режим валютного ценообразования.

Таким образом, выбранный объект исследования обладает высокой актуальностью, а имеющиеся исторические данные достоверны и репрезентативны. Обоснованное отсечение неоднородного исторического периода до валютной либерализации 2017 года обеспечивает необходимую статистическую однородность выборки. Это создает надежную и корректную базу данных, которая является полностью достаточной для построения, обучения и

объективного сравнения эффективности классических статистических моделей и передовых нейросетевых архитектур прогнозирования.

2.2 Очистка и подготовка данных

Перед построением моделей прогнозирования исходные данные были подвергнуты процедурам очистки и предварительной обработки. Целью данного этапа является обеспечение корректности и сопоставимости данных, а также подготовка их к использованию в различных моделях прогнозирования. Как отмечается в эконометрической литературе, точность любого прогноза строго ограничивается достоверностью и качеством тех данных, на которых он построен.

На первом этапе была проведена проверка исходного набора данных на наличие пропущенных значений и дубликатов. В ходе анализа установлено, что пропуски отсутствуют, а временной ряд является непрерывным и корректно упорядоченным по времени. Это полностью удовлетворяет базовым требованиям, предъявляемым к эмпирическим данным для статистического анализа и прогнозирования.

Одним из важнейших условий сопоставимости уровней интервального ряда является однородность этапов, в пределах которых показатель подчиняется единому закону развития. В связи с выявленным структурным разрывом временного ряда, обусловленным масштабной либерализацией валютного рынка в 2017 году, из дальнейшего анализа был исключен период до сентября 2017 года. Сохранение данных до этого структурного сдвига неизбежно привело бы к смещению оценок и искажению параметров обучаемых алгоритмов.

Для объективной оценки качества моделей данные были разделены на обучающую (train) и тестовую (test) выборки в соотношении 80/20. Поскольку тестовые данные применяются исключительно для независимой оценки предсказательной способности (генерализации) и не участвуют в подборе параметров, это позволяет получить достоверное представление о том, как модель будет вести себя на новых данных [23]. Разделение производилось строго с учетом временной структуры данных без случайного перемешивания наблюдений. Во временных рядах случайное перемешивание недопустимо, так как оно разрушает автокорреляционную структуру и хронологическую зави-

симость наблюдений.

Для обеспечения корректной работы моделей машинного обучения и нейросетевых архитектур была выполнена нормализация данных с использованием метода Min-Max масштабирования [13]. Нейронные сети высокочувствительны к масштабу входных значений: приведение данных к единому диапазону (от 0 до 1) существенно ускоряет сходимость алгоритмов оптимизации и предотвращает доминирование признаков с изначально большими числовыми значениями. Процесс масштабирования инициализируется следующим образом:

```
1 scaler = MinMaxScaler()
```

Критически важно отметить, что адаптация параметров масштабирования (поиск минимума и максимума) выполнялась только на обучающей выборке. Тестовая выборка трансформировалась на основе параметров, полученных из обучающей. Это строгое методическое правило необходимо для предотвращения так называемой «утечки данных» (data leakage) — недопустимого попадания информации из будущего тестового периода в процесс обучения модели.

Стандартные алгоритмы машинного обучения по умолчанию не воспринимают хронологический порядок, поэтому временной контекст необходимо задавать явно через конструирование признаков (feature engineering). Для учета временной зависимости значений временного ряда были сформированы лаговые признаки, представляющие собой значения курса за предыдущие моменты времени. В частности, были использованы значения курса за несколько предыдущих дней (лаговые переменные). Лаги формировались на основе исходных (ненормализованных) значений курса путем сдвига временного ряда назад, что в программной среде реализуется следующим образом:

```
1 for lag in range(1, 8):  
2     df[f'lag_{lag}'] = df['usd_uzs'].shift(lag)
```

Создание лагов позволяет регрессионным алгоритмам выявлять автокорреляционные зависимости и предсказывать текущее значение на основе недавней исторической памяти рынка.

В результате формирования лаговых признаков (из-за смещения значений) в самом начале временного ряда закономерно возникли пропущенные значения (NaN). Поскольку большинство моделей машинного обучения

не способно обрабатывать векторы с отсутствующими данными, эти пустые строки были удалены из выборки.

Подготовленный набор данных был сохранён в отдельный файл для дальнейшего использования, что гарантирует воспроизводимость экспериментов на различных этапах моделирования:

```
1 df.to_csv('data/processed_data.csv', index=False)
```

Специфика применяемых в работе алгоритмов требует различного формата представления входных переменных. Подготовка данных осуществлялась с учетом архитектурных особенностей используемых моделей: Для классических статистических моделей (ARIMA) использовался исходный (непреобразованный) временной ряд, так как авторегрессионные компоненты формируются и дифференцируются внутри самой математической модели. Для моделей машинного обучения (ML) использовались сформированные лаговые признаки в виде традиционной двумерной матрицы «объект-признак». Для нейросетевых моделей (LSTM) формировались специфические последовательности наблюдений в виде трехмерных тензоров, что является обязательным требованием для рекуррентных слоев, обрабатывающих хронологию и внутренние состояния.

Таким образом, исходные данные были очищены, преобразованы и подготовлены для дальнейшего применения различных методов прогнозирования, что обеспечивает корректность, математическую обоснованность и сопоставимость результатов в ходе последующего моделирования.

2.3 Постановка задачи прогнозирования

В рамках данного исследования решается задача прогнозирования значений временного ряда валютного курса. С точки зрения машинного обучения данная задача относится к классу задач регрессии [21; 22]. Решение этой задачи позволяет на основе математического анализа исторических данных экстраполировать выявленные закономерности на неопределенное будущее, что критически важно для принятия решений в условиях нестабильных финансовых рынков.

Основой прогнозирования временных рядов является предположение о том, что будущее состояние системы зависит от ее прошлой динамики. Пусть имеется дискретный временной ряд значений валютного курса y_t , где t обо-

значает последовательные моменты времени. На основе предыдущих исторических значений $y_{t-1}, y_{t-2}, \dots, y_{t-n}$ требуется предсказать значение y_t . Математически это сводится к поиску некоторой функции прогнозирования f , которая с минимальной случайной ошибкой аппроксимирует зависимость текущего курса от его прошлых (лаговых) реализаций.

Для применения алгоритмов машинного обучения временная последовательность преобразуется в стандартный матричный вид. В качестве входных данных (матрицы X) используются лаговые признаки, сформированные на основе предыдущих значений временного ряда за заданное окно (окно наблюдений). Целевой переменной (вектором y) является фактическое значение валютного курса на текущий момент времени. Таким образом, в процессе обучения алгоритмы пытаются выявить скрытую связь между сформированным вектором исторических лагов и фактической котировкой.

Важнейшим параметром постановки задачи является глубина предсказания во времени. В работе рассматривается задача одношагового прогнозирования (one-step-ahead forecast), при которой на основе предыдущих значений предсказывается значение ровно на следующий момент времени. В контексте дневных данных валютного рынка это означает прогноз курса на один следующий торговый день. Выбор одношагового горизонта обусловлен высокой волатильностью финансовых рынков, где многошаговые прогнозы часто приводят к сильному накоплению ошибки.

Для объективного измерения предсказательной способности обученных алгоритмов необходимо задать математические критерии. Для оценки качества прогнозирования используются следующие метрики: средняя абсолютная ошибка (MAE), средняя квадратичная ошибка (MSE), корень из средней квадратичной ошибки (RMSE) и средняя абсолютная ошибка в процентах (MAPE).

- MAE (Mean Absolute Error) вычисляется как среднее из абсолютных разностей между фактическими и прогнозными значениями:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Эта метрика легко интерпретируется и показывает среднее линейное отклонение прогноза в тех же единицах, что и сам ряд (в суммах за дол-

лар).

- MSE (Mean Squared Error) определяется по формуле

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Данная метрика представляет собой среднее арифметическое квадратов отклонений прогноза от фактических значений. Возведение в квадрат обеспечивает повышенную чувствительность к крупным ошибкам. RMSE является корнем из MSE и возвращает ошибку в исходные единицы измерения.

- RMSE (Root Mean Squared Error) определяется по формуле

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Особенность RMSE заключается в том, что возведение в квадрат заставляет метрику сильнее «штрафовать» модель за крупные ошибки (выбросы) прогноза.

- MAPE (Mean Absolute Percentage Error) — средняя абсолютная ошибка в процентах — определяется по формуле

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%$$

Данная метрика позволяет оценить точность прогнозирования в безразмерных (относительных) величинах, что упрощает экономическую интерпретацию результатов и делает их сопоставимыми для рядов различного масштаба.

Основное правило интерпретации всех перечисленных метрик: чем меньше получаемое значение, тем ближе предсказания модели к реальным историческим данным и тем выше ее качество.

Весь процесс решения задачи строится в виде строгого последовательного алгоритма. Процесс решения задачи включает подготовку и нормализа-

цию данных, обучение выбранных моделей на тренировочной выборке, получение одношаговых прогнозов и последующее сравнение их качества на тестовой выборке с использованием метрик MAE, MSE, RMSE и MAPE.

Таким образом, задача прогнозирования валютного курса формализована в виде задачи регрессии с использованием лаговых признаков. Сформулированный одношаговый горизонт и метрики оценки качества создают необходимый математический фундамент. Это позволяет применять как классические статистические методы, так и современные алгоритмы машинного обучения и нейросетевые модели в сопоставимых условиях.

2.4 Используемые модели

Для решения задачи прогнозирования валютного курса в работе используются модели различных классов, представляющие как традиционную эконометрику, так и передовые алгоритмы машинного обучения. Это позволяет провести комплексное и всестороннее сравнение их эффективности на реальных исторических данных.

В рамках исследования рассматриваются следующие модели:

- модель ARIMA;
- модель Random Forest;
- нейросетевая модель LSTM.

Модель ARIMA (интегрированная модель авторегрессии и скользящего среднего) представляет собой классический статистический подход к прогнозированию временных рядов, основанный на использовании авторегрессии и скользящего среднего с предварительным приведением данных к стационарному виду. Данная модель широко применяется в эконометрике и бизнес-аналитике, обладая прочной математической базой. В контексте данного исследования она служит надежным базовым ориентиром (benchmark) для объективного сравнения с более сложными нелинейными методами.

Модель Random Forest относится к классу ансамблевых методов машинного обучения и основана на построении множества деревьев решений. Данный алгоритм способен выявлять сложные нелинейные зависимости между признаками и целевой переменной. В рамках исследования мо-

дель используется для оценки эффективности методов машинного обучения при прогнозировании временных рядов на основе лаговых признаков.

Модель LSTM (Long Short-Term Memory) относится к классу рекуррентных нейронных сетей (RNN) и специально предназначена для обработки последовательных данных. Благодаря наличию внутренних механизмов памяти и управляющих шлюзов (gates), алгоритм решает проблему затухающего градиента. Она эффективно учитывает долгосрочную временную зависимость и успешно используется для прогнозирования сложных, волатильных и нелинейных финансовых временных рядов.

Выбор указанных моделей обусловлен необходимостью сопоставления различных подходов к прогнозированию. Модель ARIMA представляет проверенные временем классические статистические методы и линейный подход к анализу, Random Forest — методы машинного обучения, тогда как LSTM — современные нейросетевые архитектуры, способные выявлять глубокие нелинейные паттерны. Такое сочетание позволяет провести наиболее объективный анализ эффективности различных подходов в условиях высокой волатильности валютного рынка.

2.5 Обоснование выбора гиперпараметров моделей

Качество прогноза любой модели напрямую зависит от значений её гиперпараметров — настроек, которые задаются до обучения и не подбираются самим алгоритмом в процессе оптимизации. В данном разделе обосновывается выбор ключевых гиперпараметров для каждой из трёх используемых моделей.

Модель ARIMA определяется тремя параметрами: p — порядок авторегрессии (число прошлых значений ряда, используемых для прогноза), d — порядок интегрирования (число последовательных дифференцирований, необходимых для приведения ряда к стационарному виду), и q — порядок скользящего среднего (число прошлых ошибок прогноза). Подбор этих параметров вручную через анализ автокорреляционной (ACF) и частной автокорреляционной (PACF) функций является трудоёмким и субъективным. Поэтому в работе использован автоматический подбор с помощью процедуры `auto_arima` из библиотеки `pmdarima`, которая перебирает возможные комбинации (p, d, q) и выбирает оптимальную по информационному критерию

Акаике (AIC).

Критерий AIC оценивает качество модели с учётом штрафа за её сложность и вычисляется по формуле

$$AIC = 2k - 2 \ln(\hat{L}),$$

где k — число оцениваемых параметров модели, а $\hat{L}$ — максимум функции правдоподобия. Минимизация AIC позволяет найти компромисс между точностью аппроксимации и риском переобучения: модель не должна быть ни слишком простой (высокая ошибка), ни избыточно сложной (переобучение на шуме). Перебор выполнялся в пошаговом (stepwise) режиме без учёта сезонной компоненты, поскольку для ежедневного валютного ряда выраженная сезонность не характерна.

В результате автоматического подбора оптимальной по AIC была признана модель **ARIMA(4,1,2)**. Значение $d = 1$ означает, что для достижения стационарности достаточно однократного дифференцирования (перехода к первым разностям курса), что согласуется с природой валютных рядов, близких к процессу случайного блуждания. Порядок авторегрессии $p = 4$ указывает на то, что текущее приращение курса статистически зависит от четырёх предыдущих приращений, а порядок скользящего среднего $q = 2$ — на учёт двух последних ошибок прогноза. Таким образом, выбор параметров ARIMA не является произвольным, а определён формальным статистическим критерием.

Для модели случайного леса ключевым гиперпараметром является число деревьев в ансамбле `n_estimators`, которое в работе установлено равным **100**. Увеличение числа деревьев повышает устойчивость прогноза за счёт усреднения, однако после некоторого порога прирост точности становится незначительным при заметном росте вычислительных затрат. Значение 100 является общепринятым по умолчанию в библиотеке `scikit-learn` и обеспечивает разумный баланс между качеством и скоростью обучения.

Остальные гиперпараметры (максимальная глубина деревьев, минимальное число объектов в листе и в узле для разбиения) оставлены в значениях по умолчанию, что позволяет деревьям расти до полного разделения обучающих данных. Поскольку случайный лес слабо подвержен переобучению благодаря усреднению по множеству деревьев, такая конфигурация счи-

тается приемлемой для базового сравнения. Отдельно следует отметить выбор числа лаговых признаков: в качестве входных переменных используются семь предыдущих значений курса (`lag_1--lag_7`), что соответствует одной торговой неделе и позволяет модели опираться на краткосрочную динамику ряда. Для воспроизводимости результатов зафиксировано начальное состояние генератора случайных чисел (`random_state=42`).

Нейросетевая модель LSTM характеризуется большим числом гиперпараметров, основные из которых — размер входного окна, число нейронов, параметры обучения и механизм ранней остановки. Размер окна `WINDOW_SIZE` установлен равным **10**: модель использует значения курса за десять предыдущих дней для прогноза следующего. Это значение соответствует примерно двум торговым неделям и обеспечивает достаточный контекст для выявления краткосрочных зависимостей, не перегружая модель избыточной историей.

Архитектура сети включает один рекуррентный слой LSTM из 50 нейронов и полносвязный выходной слой с одним нейроном, формирующим итоговый прогноз. Обучение проводится с помощью оптимизатора Adam при функции потерь в виде среднеквадратичной ошибки (MSE). Число эпох ограничено значением 50, размер мини-батча — 32, а 10% обучающей выборки выделяется под валидацию. Для предотвращения переобучения применяется механизм ранней остановки (EarlyStopping) с терпением в пять эпох: если ошибка на валидации не улучшается на протяжении пяти эпох подряд, обучение прекращается, а веса откатываются к наилучшему достигнутому состоянию. Как и для остальных моделей, зафиксировано начальное состояние генераторов случайных чисел, что обеспечивает воспроизводимость результатов.

Выбранные гиперпараметры моделей основаны на формальных критериях, общепринятых настройках и особенностях исследуемых данных, что обеспечивает корректность и воспроизводимость результатов.

В следующей главе будет выполнено обучение моделей на подготовленных данных и проведено сравнение их прогностических характеристик.

Глава 3. Практическая реализация (эксперименты и результаты)

3.1 Результаты обучений классических моделей

Для построения базового статистического прогноза временного ряда валютного курса была использована модель ARIMA. Данный подход традиционно применяется в эконометрике в качестве классического метода анализа временных рядов. В рамках данного исследования он используется как базовая модель (benchmark) для последующего объективного сравнения с более сложными алгоритмами машинного обучения и современными нейросетевыми архитектурами глубокого обучения.

Для определения оптимальной конфигурации модели использовался автоматизированный подбор параметров на основе минимизации информационного критерия Акаике (AIC) [14]. Данный критерий является эффективным инструментом, так как он представляет собой компромисс между качеством подгонки модели к историческим данным и ее сложностью («экономией»), налагая штраф за избыточное число параметров. В результате была выбрана модель ARIMA(4,1,2), показавшая наилучшее качество (минимальное значение AIC) среди рассмотренных вариантов.

Фрагмент вывода результатов подбора параметров:

```
1 ARIMA(4 , 1 , 2) ( 0 , 0 , 0) [ 0] intercept : AIC=21290.552 , Time=1.97  
   sec
```

Обучение модели выполнялось на обучающей выборке временного ряда с использованием библиотеки statsmodels языка программирования Python. Алгоритм осуществляет оценку параметров авторегрессии и скользящего среднего, минимизируя среднеквадратичную ошибку на тренировочных данных.

```
1 from statsmodels.tsa.arima.model import ARIMA  
2     # Обучаем _ модель _ натекущей _ истории_  
3 model      = ARIMA(history , order=best_order)  
4 model_fit = model.fit()
```

После завершения обучения модели был построен прогноз значений валютного курса на тестовой выборке. Для повышения реалистичности про-

гнозирования в работе использовался подход rolling forecast (скользящего прогнозирования). В отличие от прямого многошагового прогнозирования, при котором модель строит прогноз сразу на весь тестовый интервал, rolling forecast (или метод скользящего окна с переоценкой) предполагает последовательное выполнение одношаговых прогнозов.

На каждом шаге модель обучалась на текущем наборе доступных данных, после чего выполнялся прогноз только на один следующий момент времени. Затем фактическое (реальное) значение добавлялось в обучающую историю, и процедура повторялась снова. Такой подход позволяет модели постоянно адаптироваться к изменяющейся динамике временного ряда, усваивать свежие рыночные шоки и обеспечивает более высокую точность краткосрочного прогнозирования.

Для оценки качества прогнозирования использовались метрики MAE, MSE, RMSE и MAPE. Средняя абсолютная ошибка (MAE) и корень из среднеквадратичной ошибки (RMSE) измеряют абсолютные отклонения прогноза, при этом RMSE сильнее «штрафует» модель за крупные выбросы. Средняя абсолютная ошибка в процентах (MAPE) позволяет оценить точность в безразмерных (относительных) величинах, что упрощает экономическую интерпретацию. Для всех перечисленных метрик действует правило: чем меньше полученное значение, тем выше точность прогноза и лучше работает модель. Полученные результаты оценки классической модели представлены в таблице 3.1.

Таблица 3.1: Результаты оценки точности модели ARIMA

Метрика	Значение
MAE	19,05 сум
MSE	815,10 сум ²
RMSE	28,55 сум
MAPE	0,15%

Для наглядной оценки поведения алгоритма полученные прогнозные значения были наложены на фактический график тестовой выборки валютного курса.

На рисунке видно, что модель ARIMA достаточно хорошо воспроизводит общую динамику временного ряда и корректно улавливает долгосрочный восходящий тренд изменения курса. При этом в отдельных участках наблю-




Рис. 3.1: Сравнение реальных и прогнозируемых значений модели ARIMA

даются отклонения прогноза от реальных значений, особенно в периоды повышенной волатильности, где классическая линейная модель склонна к излишнему сглаживанию локальных ценовых пиков.

Модель ARIMA с использованием подхода *rolling forecast* демонстрирует высокую степень совпадения прогнозируемых и реальных значений временного ряда. Модель успешно воспроизводит общую динамику изменения валютного курса и корректно реагирует на локальные колебания ряда благодаря механизму постоянного обновления истории. Полученные значения метрик ($\text{MAPE} = 0.15\%$) свидетельствуют о высоком качестве краткосрочного прогнозирования. Тем не менее, заметное сглаживание пиковых скачков указывает на фундаментальные ограничения линейного статистического подхода в условиях резкой волатильности, что подтверждает целесообразность исследования более сложных нейросетевых архитектур.

Важно отметить, что подход *rolling forecast* предполагает переобучение модели на каждом шаге с добавлением фактического значения в обучающую выборку. Это даёт модели существенное методологическое преимущество по сравнению с алгоритмами, обученными однократно. Для объективного сравнения ARIMA с другими моделями (Random Forest и LSTM), которые обучаются один раз, был дополнительно проведён эксперимент с использованием статического прогноза ARIMA (без переобучения).

В данном режиме модель ARIMA(4,1,2) обучалась один раз на обучающей выборке, после чего формировала прогноз на весь тестовый период без

обновления параметров. Результаты представлены в таблице 3.2.

Таблица 3.2: Результаты оценки точности модели ARIMA (статический прогноз)

Метрика	Значение
MAE	235,35 сум
MSE	93 165,35 сум ²
RMSE	305,23 сум
MAPE	1,89%




Рис. 3.2: Сравнение реальных и прогнозируемых значений модели ARIMA (статический прогноз)

Результаты статического прогноза значительно уступают rolling forecast по всем метрикам: MAE возросла более чем в 12 раз (с 19,05 до 235,35 сумов), а MAPE увеличилась с 0,15% до 1,89%. Это наглядно демонстрирует, что высокая точность модели ARIMA в предыдущем эксперименте во многом обусловлена именно механизмом постоянного переобучения. Без переобучения линейная модель быстро теряет актуальность на протяжённых тестовых интервалах.

Данный эксперимент обеспечивает методологически корректную базу для сравнения: статическая ARIMA, Random Forest и LSTM обучаются на одних и тех же данных без доступа к будущим значениям, что делает сопоставление их результатов объективным.

3.2 Результаты ML-моделей

Для исследования возможностей методов машинного обучения в задаче прогнозирования валютного курса была использована модель Random Forest. Данный алгоритм выбран как один из наиболее распространенных ансамблевых методов регрессии, способный выявлять нелинейные зависимости между признаками и целевой переменной.

В отличие от модели ARIMA, алгоритм Random Forest не учитывает временную структуру данных напрямую. Поэтому для обучения модели были сформированы лаговые признаки, представляющие собой значения валютного курса за предыдущие периоды времени.

В базовой конфигурации модели использовались семь лаговых признаков, соответствующих значениям курса за семь предыдущих дней. Дополнительно был проведен эксперимент с использованием тридцати лаговых признаков. Однако увеличение количества признаков не привело к улучшению качества прогнозирования и сопровождалось ростом значений ошибок. Это связано с тем, что добавление избыточного количества лагов может вносить дополнительный информационный шум и декоррелировать работу деревьев в ансамбле неоптимальным образом.

Таблица 3.3: Результаты оценки точности модели Random Forest с 30 лагами

Метрика	Значение
MAE	133,97 сум
MSE	27 168,93 сум ²
RMSE	164,83 сум
MAPE	1,05%

Поэтому для дальнейшего анализа была выбрана конфигурация с семью лагами.

Обучение модели выполнялось на обучающей выборке с использованием библиотеки Scikit-Learn языка программирования Python. Для построения ансамбля использовалось 100 деревьев решений. Суть метода заключается в том, что каждое дерево независимо обучается на случайной подвыборке, а итоговый результат усредняется, что позволяет существенно снизить общую дисперсию модели и избежать переобучения. Для обеспечения воспроизводимости эксперимента использовалась фиксированная инициализация генератора случайных чисел.




Рис. 3.3: Сравнение реальных и прогнозируемых значений модели Random Forest(30 лагов)

После завершения обучения модель была применена к тестовой выборке для получения прогнозных значений валютного курса. В ходе данного этапа на вход обученному алгоритму подавались векторы сформированных лаговых признаков, на основе которых формировался точечный одношаговый прогноз.

Для количественной оценки качества прогнозирования использовались метрики MAE, MSE, RMSE и MAPE. Полученные результаты представлены в таблице 3.4.

Таблица 3.4: Результаты оценки точности модели Random Forest с 7 лагами

Метрика	Значение
MAE	112,01 сум
MSE	21 503,29 сум ²
RMSE	146,64 сум
MAPE	0,88%

Для наглядной оценки поведения модели полученные прогнозные значения были наложены на фактический график тестовой выборки.

На рисунке видно, что модель Random Forest в целом воспроизводит основные тенденции временного ряда. Вместе с тем прогноз демонстрирует склонность к сглаживанию резких изменений курса и приближению к среднему уровню ряда. На участках продолжительного тренда наблюдаются отклонения прогнозируемых значений от фактических данных. Это объясняет-




Рис. 3.4: Сравнение реальных и прогнозируемых значений модели Random Forest(7 лагов)

ся математической спецификой алгоритмов на основе деревьев: случайный лес осуществляет усреднение значений в терминальных узлах (листьях) и принципиально не способен экстраполировать значения, выходящие за пределы тех, на которых он обучался.

Таким образом, модель Random Forest показала способность прогнозировать общую динамику валютного курса и обеспечила приемлемое качество прогноза. Проведенный эксперимент также показал, что увеличение числа лаговых признаков с 7 до 30 не приводит к улучшению результатов. Полученные данные будут использованы на следующем этапе исследования для последующего сравнения с другими моделями прогнозирования (в частности, с рекуррентными нейронными сетями).

3.3 Построение и обучение LSTM

Нейросетевые алгоритмы, в особенности рекуррентные сети, обладают высокой чувствительностью к масштабу входных данных. Для обеспечения корректной работы алгоритмов оптимизации и ускорения сходимости весов использовался предварительно нормализованный ряд. Приведение всех значений валютного курса к единому диапазону от 0 до 1 осуществлялось с применением метода минимаксного масштабирования (MinMaxScaler). Масштабирование выполнялось строго на обучающей выборке, после чего полученные параметры преобразования применялись к тестовой выборке для

исключения утечки данных. В отличие от классических моделей и простых алгоритмов машинного обучения, архитектура LSTM принимает на вход данные в виде трехмерного тензора (образцы, временные шаги, признаки). Для учета временной зависимости производилось формирование последовательностей методом скользящего окна. В данной конфигурации использовалось окно длиной 10 наблюдений: для прогнозирования курса на следующий день на вход нейросети подавалась последовательность значений за 10 предыдущих дней. Такое окно позволяет алгоритму уловить краткосрочные паттерны и локальные тренды. Разделение набора данных на обучающую (train) и тестовую (test) выборки производилось в пропорции 80/20. Разделение выполнялось строго в хронологическом порядке без перемешивания, чтобы сохранить естественную структуру временного ряда.

Для решения задачи прогнозирования использовалась рекуррентная нейронная сеть долгой краткосрочной памяти (Long Short-Term Memory, LSTM) [11]. Эта архитектура разработана специально для преодоления проблемы затухающего градиента и способна эффективно выявлять долгосрочные зависимости в последовательных данных благодаря системе внутренних шлюзов (gates). Спроектированная архитектура сети включает один скрытый слой LSTM, состоящий из 50 нейронов. Данного количества достаточно для извлечения скрытых признаков из финансовых рядов без чрезмерного усложнения модели. За ним следует полносвязный выходной слой Dense(1) с линейной функцией активации, который агрегирует извлеченные признаки и выдает итоговое предсказанное значение валютного курса. В качестве функции потерь (loss function) использовалась среднеквадратичная ошибка (MSE) — стандартная метрика для задач регрессии, минимизация которой позволяет обучать параметры модели. В качестве алгоритма оптимизации был выбран передовой оптимизатор Adam (Adaptive Moment Estimation), который комбинирует идеи накопления импульса и адаптивной скорости обучения для каждого параметра, что делает его крайне эффективным для обучения глубоких нейросетей. Сводная информация по архитектуре модели и количеству обучаемых параметров (`model.summary()`) представлена в таблице 3.5.

Процесс обучения модели заключался в итеративной корректировке весов для минимизации функции потерь. Максимальное число эпох было установлено равным 50 (`epochs=50`). Для обновления градиентов данные разби-

Таблица 3.5: Архитектура модели LSTM

Layer (type)	Output Shape	Param #
lstm (LSTM)	(None, 50)	10 400
dense (Dense)	(None, 1)	51
Всего параметров:	10 451 (40.82 КБ)	
Обучаемых параметров:	10 451 (40.82 КБ)	
Необучаемых параметров:	0	

валились на пакеты (`batch_size=32`), что позволяет сбалансировать скорость вычислений и стабильность сходимости. Дополнительно в процессе обучения 10% обучающей выборки выделялось под валидацию (`validation_split=0.1`). Это необходимо для независимого контроля качества: после каждой эпохи вычислялась ошибка на валидационном наборе, что позволяло отслеживать потенциальное переобучение (*overfitting*). Для предотвращения переобучения и автоматической остановки обучения применялся механизм ранней остановки (*EarlyStopping*) с параметром терпения `patience=5`: если в течение пяти последовательных эпох валидационная ошибка не уменьшалась, обучение прекращалось, а веса модели восстанавливались до состояния с наименьшей ошибкой.




Рис. 3.5: Динамика функции потерь (MSE) в процессе обучения модели LSTM

На рисунке видно, что значения функции потерь быстро снижаются в первые эпохи обучения и далее стабилизируются. Существенного расхождения между обучающей и валидационной ошибками не наблюдается, что

свидетельствует об отсутствии выраженного переобучения модели.

После завершения процесса обучения модель была протестирована на отложенной (тестовой) выборке, которую алгоритм ранее не наблюдал. Модель получала на вход историческое окно из 10 наблюдений и формировала одношаговый прогноз.




Рис. 3.6: Сравнение фактических и прогнозных значений курса USD/UZS (модель LSTM)

На рисунке представлено сравнение фактических значений курса USD/UZS и прогнозных значений, полученных с помощью модели LSTM. Модель успешно воспроизводит общий тренд временного ряда и корректно отслеживает основные изменения курса валюты. При этом наблюдается некоторое сглаживание краткосрочных колебаний, характерное для нейросетевых моделей данного типа.

Для количественной оценки качества прогнозирования были использованы показатели MAE, MSE, RMSE и MAPE. Результаты расчета метрик ошибки на тестовой выборке представлены в таблице 3.6.

Таблица 3.6: Метрики качества модели LSTM

Метрика	Значение
MAE	40,74 сум
MSE	2 956,10 сум ²
RMSE	54,37 сум
MAPE	0,33%

Полученные результаты свидетельствуют о высокой точности прогноза. Средняя относительная ошибка составила 0,33 %, что подтверждает способность модели эффективно выявлять закономерности изменения валютного курса.

Таким образом, модель LSTM продемонстрировала высокое качество прогнозирования курса USD/UZS. Использование рекуррентной архитектуры позволило учитывать временные зависимости во входных данных и получать прогнозы, близкие к фактическим значениям. Полученные результаты будут использованы на следующем этапе исследования для сравнительного анализа с моделями ARIMA и Random Forest.

3.4 Сравнение результатов всех моделей

Для объективной оценки эффективности рассмотренных моделей было проведено количественное сравнение их предсказательной способности по метрикам MAE, MSE, RMSE и MAPE. Сводные результаты оценки на тестовой выборке представлены в таблице 3.7. Для обеспечения корректности сравнения модели сгруппированы по методологии обучения: ARIMA (rolling forecast) выделена отдельно, поскольку она переобучается на каждом шаге, тогда как остальные три модели обучаются однократно.

Таблица 3.7: Сравнение метрик качества прогнозирования различных моделей

Модель	MAE, сум	MSE, сум ²	RMSE, сум	MAPE, %
<i>С переобучением (rolling forecast)</i>				
ARIMA (rolling)	19,05	815,10	28,55	0,15
<i>Без переобучения (статический прогноз)</i>				
LSTM	40,74	2 956,10	54,37	0,33
Random Forest	112,01	21 503,29	146,64	0,88
ARIMA (static)	235,35	93 165,35	305,23	1,89

Данные таблицы позволяют сделать несколько ключевых наблюдений. Модель ARIMA с использованием rolling forecast показала наименьшие абсолютные значения ошибок (MAE = 19,05 сумов, MAPE = 0,15%), однако данный результат обусловлен не только свойствами самой модели, но и методологическим преимуществом: на каждом шаге модель переобучается с учётом фактических значений, недоступных другим алгоритмам.

При сопоставлении моделей в равных условиях (однократное обу-

чение) наилучшие результаты продемонстрировала нейросетевая модель LSTM ($MAE = 40,74$, $MAPE = 0,33\%$), значительно опередив как Random Forest ($MAE = 112,01$), так и статическую ARIMA ($MAE = 235,35$). Это свидетельствует о том, что рекуррентная архитектура способна эффективнее улавливать сложные временные зависимости при отсутствии возможности постоянного переобучения.

Визуальный анализ результатов показал, что все рассматриваемые модели способны воспроизводить общий долгосрочный тренд изменения валютного курса, однако характер прогнозов существенно различается. Модель ARIMA (rolling) наиболее точно отслеживает краткосрочные изменения благодаря постоянному переобучению. Модель LSTM успешно воспроизводит динамику курса и демонстрирует хорошую адаптацию к изменениям тренда, хотя и склонна сглаживать резкие ценовые колебания. Модель Random Forest ориентируется на усреднённые исторические значения и хуже реагирует на структурные изменения курса. Статическая ARIMA показывает быструю потерю точности при удалении от обучающей выборки, что объясняется накоплением ошибки в многошаговом прогнозе линейной модели.

Для наглядного сопоставления поведения всех моделей на тестовом периоде прогнозные значения каждого алгоритма были наложены на единый график вместе с фактическим курсом USD/UZS (рис. 3.7).



Рис. 3.7: Совмещённый график прогнозов всех моделей на тестовой выборке

Совмещённый график позволяет выделить ряд ключевых визуальных закономерностей. Прогноз модели ARIMA (rolling forecast) практически сливается с линией реального курса на протяжении всего тестового периода, что

подтверждает высокую точность одношагового прогноза при постоянном переобучении. Модель LSTM, несмотря на отсутствие доступа к новым данным после обучения, демонстрирует способность воспроизводить не только общий тренд, но и среднесрочные колебания курса. Её прогнозная кривая остаётся вблизи фактических значений на протяжении всего тестового интервала.

Прогноз модели Random Forest занимает промежуточное положение: алгоритм корректно воспроизводит направление тренда, однако его прогнозная кривая характеризуется ступенчатостью и склонностью к усреднению, что объясняется принципом работы ансамбля деревьев решений — каждое дерево выдаёт значение из конечного множества значений обучающей выборки. В результате модель не способна выдавать прогнозные значения за пределами исторического диапазона, что приводит к систематическому занижению прогноза при росте курса и завышению при его падении.

Наиболее заметным на графике является поведение статической модели ARIMA. Её прогноз представляет собой практически прямую линию с незначительным положительным наклоном, которая быстро расходится с реальным курсом. Данное поведение обусловлено математическими свойствами модели: при многошаговом прогнозе без обновления данных авторегрессионные и скользящие средние компоненты затухают, и прогноз сводится к линейной экстраполяции на основе среднего приращения ряда. Это наглядно демонстрирует фундаментальное ограничение линейных моделей при долгосрочном прогнозировании нестационарных финансовых рядов.

Таким образом, визуальный анализ совмещённого графика согласуется с количественными метриками и дополнительно подтверждает, что модель LSTM обеспечивает наилучшее качество прогнозирования среди моделей с однократным обучением, а высокая точность rolling forecast ARIMA обусловлена прежде всего методологическим преимуществом постоянного переобучения.

Сравнение моделей исключительно по метрикам ошибки не даёт полной картины, так как каждый алгоритм обладает своими фундаментальными особенностями. Основные преимущества и недостатки систематизированы в таблице 3.8.

Результаты исследования показывают, что выбор оптимальной модели напрямую зависит от поставленной задачи и доступных вычислительных

Таблица 3.8: Преимущества и недостатки моделей прогнозирования

Модель	Преимущества	Недостатки
ARIMA	Высокая точность на коротких горизонтах, простота математической интерпретации	Строго требует стационарности ряда, плохо улавливает сложную нелинейность
Random Forest	Простота обучения, устойчивость к выбросам и статистическому шуму, не требует масштабирования	Хуже учитывает внутреннюю временную структуру, не способна экстраполировать тренд за пределы обучающей выборки
LSTM	Способна выявлять сложнейшие нелинейные зависимости и сохранять долгосрочную память о поведении ряда	Более высокая вычислительная сложность, требует больших объемов данных, является «черным ящиком»

ресурсов. Модель ARIMA с использованием rolling forecast продемонстрировала наилучшие абсолютные результаты, однако данный подход требует переобучения на каждом шаге. При сравнении в равных условиях (однократное обучение) наиболее точной оказалась нейросетевая модель LSTM, обладающая значительно более высокой гибкостью и потенциалом для многошагового прогнозирования.

3.5 Интерпретация результатов

Проведённое исследование выявило два ключевых результата. Во-первых, при использовании rolling forecast модель ARIMA показала наивысшую точность одношагового прогноза, что объясняется как свойствами самой модели, так и преимуществом постоянного переобучения. Во-вторых, в условиях однократного обучения (корректное сравнение) нейросетевая модель LSTM значительно превзошла и Random Forest, и статическую ARIMA.

Превосходство ARIMA (rolling) объясняется спецификой исследуемого временного ряда: после либерализации валютного рынка в 2017 году курс USD/UZS демонстрировал устойчивый девальвационный тренд с умеренной волатильностью. В таких условиях линейная модель, постоянно адаптирующая свои параметры к новейшим данным, способна давать предельно точные краткосрочные прогнозы.

Однако сравнение статической ARIMA и LSTM показало, что без постоянного переобучения линейная модель быстро теряет актуальность: её ошибка ($MAE = 235,35$) оказалась почти в 6 раз выше, чем у LSTM ($MAE = 40,74$). Это подтверждает, что нейросетевые архитектуры лучше обобщают выявленные закономерности и более устойчивы при прогнозировании на длительных горизонтах.

Сложность прогнозирования финансовых показателей заключается в том, что валютный курс определяется не только собственной историей изменения, но и макроэкономическими факторами: уровнем инфляции, процентными ставками, состоянием платежного баланса, действиями Центрального банка и общей внешнеэкономической конъюнктурой.

В настоящем исследовании применялся подход «чисто временного ряда», при котором для моделирования использовались исключительно исторические значения самого курса. Это накладывает ограничения на предельную точность прогнозирования, так как внешние макроэкономические шоки способны вызывать резкие структурные сдвиги, которые невозможно предсказать исключительно на основе прошлых котировок.

Несмотря на указанные ограничения, полученные результаты могут быть использованы для краткосрочного прогнозирования валютного курса и служить количественной основой для принятия управленческих решений в финансовой и банковской сфере. Для оперативного прогнозирования с постоянным переобучением оптимальна модель ARIMA. Для автономного прогнозирования без возможности постоянного переобучения наиболее перспективна модель LSTM.

Усреднённые по всему тестовому интервалу метрики не отражают того, что точность моделей существенно меняется во времени. Для более глубокого анализа тестовый период (с апреля 2024 года по декабрь 2025 года) был разбит на полугодовые интервалы, и для каждого из них вычислена средняя абсолютная ошибка (MAE) каждой модели. Результаты приведены в таблице 3.9. Для сопоставления в последнем столбце указан средний модуль дневного изменения курса — показатель локальной волатильности ряда.

Анализ распределения ошибок во времени позволяет сделать несколько важных выводов.

Во-первых, прослеживается чёткая связь между величиной ошибки и

Таблица 3.9: Средняя абсолютная ошибка моделей по периодам

Период	ARIMA static	RF	LSTM	ARIMA rolling	Волатильность
1-е полугодие 2024 (с апр.)	40	29	33	13	13,1
2-е полугодие 2024	117	84	25	11	10,6
1-е полугодие 2025	268	220	37	16	15,4
2-е полугодие 2025	382	59	62	32	32,2

волатильностью ряда. В наиболее спокойные периоды (2-е полугодие 2024 года, когда средний модуль дневного изменения курса составлял около 10–11 сум) все модели показывали минимальные ошибки. Напротив, во 2-м полугодии 2025 года, когда волатильность выросла втрое (до 32 сум в день), ошибки большинства моделей заметно увеличились. Это закономерно: резкие колебания курса, вызванные внешними макроэкономическими шоками, принципиально труднее предсказать на основе одной лишь прошлой динамики ряда.

Во-вторых, статическая модель ARIMA демонстрирует монотонный рост ошибки по мере удаления от обучающей выборки: её средняя ошибка увеличилась с 143 сум в первой половине тестового периода до 327 сум во второй (рост примерно в 2,3 раза). Это прямое следствие природы статического прогноза: обученная один раз модель экстраполирует усреднённый тренд от конца обучающей выборки, и накопленное расхождение с фактическим курсом растёт с горизонтом. Наибольшая единичная ошибка статической ARIMA (около 756 сум) пришлась на декабрь 2025 года — период наибольшей волатильности.

В-третьих, нейросетевая модель LSTM показала наибольшую устойчивость: её ошибка оставалась низкой на протяжении почти всего периода и лишь в самом волатильном последнем полугодии выросла примерно вдвое (с 25–37 до 62 сум). Это подтверждает способность LSTM сохранять качество прогноза при изменении рыночных условий за счёт выявленных нелинейных зависимостей. Модель Random Forest вела себя менее стабильно: её ошибка достигала максимума в первой половине 2025 года (220 сум), что указывает на чувствительность лаговых признаков к локальным структурным сдвигам.

В-четвёртых, обе модели с доступом к свежим фактическим значениям (ARIMA rolling и, в меньшей степени, Random Forest, использующий ре-

альные лаги) сохраняли низкую ошибку во всех периодах: средняя ошибка ARIMA rolling выросла лишь с 11 до 32 сум даже в самый турбулентный период. Это ещё раз подчёркивает решающую роль постоянного доступа к новым данным для краткосрочного прогнозирования.

Таким образом, ошибки моделей распределены во времени неравномерно и концентрируются в периоды повышенной волатильности и резких изменений курса. Наиболее критичным фактором роста ошибки оказывается не календарный период сам по себе, а сочетание длины горизонта прогнозирования (для статических моделей) и локальной волатильности рынка.

Заключение

Выпускная квалификационная работа была посвящена исследованию и сравнительному анализу методов прогнозирования валютного курса USD/UZS на основе классических моделей временных рядов, алгоритмов машинного обучения и современных нейросетевых архитектур.

Актуальность выбранной темы обусловлена высокой практической значимостью прогнозирования валютных курсов для финансовых организаций, предприятий внешнеэкономической деятельности, государственных структур и частных инвесторов. В условиях нестабильности финансовой среды и мировой экономики возрастает острая потребность в инструментах, позволяющих получать максимально точные и обоснованные прогнозы изменения котировок.

На этапе теоретического исследования были систематизированы основы анализа финансовых временных рядов, а также проведено математическое обоснование применения традиционных статистических методов прогнозирования, алгоритмов машинного обучения и рекуррентных нейросетевых моделей. Особое внимание было уделено специфике валютного курса как сложного экономического показателя, который характеризуется нестационарностью, высоким уровнем информационного шума и поведением, близким к случайному блужданию.

В рамках практической реализации в качестве объекта исследования был выбран официальный курс доллара США к узбекскому суму (USD/UZS). Для проведения корректного анализа использовались исторические данные исключительно за период после либерализации валютного рынка Республики Узбекистан (начиная с сентября 2017 года), что позволило исключить нерыночные структурные сдвиги. На этапе подготовки данных были выполнены все необходимые методологические процедуры: очистка временного ряда, нормализация значений и формирование лаговых признаков для обучения моделей.

В ходе эксперимента были программно реализованы и протестированы четыре конфигурации прогнозирования: статистическая модель ARIMA в двух режимах (rolling forecast с переобучением и статический прогноз без

переобучения), алгоритм ансамблевого машинного обучения Random Forest и рекуррентная нейросетевая модель долгой краткосрочной памяти (LSTM). Для объективной оценки качества прогнозирования применялся комплекс стандартных статистических метрик: средняя абсолютная ошибка (MAE), среднеквадратичная ошибка (MSE), корень из среднеквадратичной ошибки (RMSE) и средняя абсолютная ошибка в процентах (MAPE).

Основные результаты исследования показали, что все рассмотренные модели способны воспроизводить общую динамику изменения валютного курса. Наименьшие абсолютные ошибки были получены для модели ARIMA с rolling forecast (MAPE = 0,15%), однако данный подход использует механизм постоянного переобучения, что даёт методологическое преимущество перед моделями с однократным обучением. При корректном сравнении в равных условиях (без переобучения) наилучшие результаты продемонстрировала нейросетевая модель LSTM (MAPE = 0,33%), значительно превзошедшая как Random Forest (MAPE = 0,88%), так и статическую ARIMA (MAPE = 1,89%).

Проведённое исследование позволяет сделать два ключевых вывода. Во-первых, для оперативного краткосрочного прогнозирования с возможностью постоянного обновления модели наиболее эффективна ARIMA с rolling forecast. Во-вторых, при необходимости автономного прогнозирования без переобучения нейросетевая модель LSTM демонстрирует значительное превосходство над классическими методами.

Практическая значимость работы заключается в возможности использования полученных результатов и построенных моделей для краткосрочного прогнозирования валютных курсов. Предложенные алгоритмы могут применяться при разработке аналитических систем поддержки принятия решений в банковской и финансовой сфере.

Перспективы дальнейших исследований связаны с переходом к многомерному анализу, включением дополнительных макроэкономических факторов (инфляции, процентных ставок, платежного баланса), применением более сложных нейросетевых архитектур и использованием моделей ARCH/GARCH для более точного учёта волатильности финансовых рынков.

Цель выпускной квалификационной работы достигнута, а поставленные задачи выполнены в полном объёме.

Список литературы

1. *Zhang G. P.* Time Series Forecasting Using a Hybrid ARIMA and Neural Network Model // *Neurocomputing*. — 2003. — Т. 50. — С. 159—175.
2. *Enders W.* *Applied Econometric Time Series*. — 4-е изд. — John Wiley & Sons, 2015.
3. *Siarni-Namini S., Tavakoli N., Siarni Namin A.* A Comparison of ARIMA and LSTM in Forecasting Time Series // 2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA). — 2018. — С. 1394—1401. — DOI: [10.1109/ICMLA.2018.00227](https://doi.org/10.1109/ICMLA.2018.00227).
4. *Nelson D. M. Q., Pereira A. C. M., Oliveira R. A.* Stock Market's Price Movement Prediction With LSTM Neural Networks // *Proceedings of the International Joint Conference on Neural Networks (IJCNN)*. — 2017. — С. 1419—1426. — DOI: [10.1109/IJCNN.2017.7966019](https://doi.org/10.1109/IJCNN.2017.7966019).
5. *Makridakis S., Spiliotis E., Assimakopoulos V.* Statistical and Machine Learning forecasting methods: Concerns and ways forward // *PLOS ONE*. — 2018. — Т. 13, № 3. — e0194889.
6. *Hamilton J. D.* *Time Series Analysis*. — Princeton University Press, 1994.
7. *Time Series Analysis: Forecasting and Control* / G. E. P. Box [и др.]. — 5-е изд. — John Wiley & Sons, 2016.
8. *Bishop C. M.* *Pattern Recognition and Machine Learning*. — New York : Springer, 2006.
9. *Goodfellow I., Bengio Y., Courville A.* *Deep Learning*. — MIT Press, 2016.
10. *Breiman L.* Random Forests // *Machine Learning*. — 2001. — Т. 45, № 1. — С. 5—32.
11. *Hochreiter S., Schmidhuber J.* Long Short-Term Memory // *Neural Computation*. — 1997. — Т. 9, № 8. — С. 1735—1780.
12. *Центральный банк Республики Узбекистан.* Официальные курсы иностранных валют. — 2026. — URL: <https://cbu.uz> ; Дата обращения: 01.02.2026.

13. An Introduction to Statistical Learning: With Applications in R / G. James [и др.]. — 2-е изд. — Springer, 2021.
14. Hyndman R. J., Athanasopoulos G. Forecasting: Principles and Practice. — 3-е изд. — OTexts, 2021. — URL: <https://otexts.com/fpp3/>.
15. Афанасьев В. Н., Юзбашев М. М. Анализ временных рядов и прогнозирование. — Москва : Финансы и статистика, 2001. — С. 228.
16. Айвазян С. А., Мхитарян В. С. Прикладная статистика. Основы эконометрики. Том 1. Теория вероятностей и прикладная статистика. — Москва : ЮНИТИ-ДАНА, 2001.
17. Айвазян С. А. Прикладная статистика. Основы эконометрики. Том 2. Основы эконометрики. — Москва : ЮНИТИ-ДАНА, 2001.
18. Кремер Н. Ш., Путко Б. А. Эконометрика. — 3-е изд. — Москва : ЮНИТИ-ДАНА, 2010.
19. Alexander C. Market Risk Analysis. Volume I: Quantitative Methods in Finance. — Chichester : John Wiley & Sons, 2008.
20. Alexander C. Market Risk Analysis. Volume II: Practical Financial Econometrics. — Chichester : John Wiley & Sons, 2008.
21. Dougherty C. Introduction to Econometrics. — 4-е изд. — Oxford University Press, 2011.
22. Магнус Я. Р., Катышев П. К., Пересецкий А. А. Эконометрика. Начальный курс. — Москва : Дело, 2004.
23. Вербик М. Путеводитель по современной эконометрике. — Москва : Научная книга, 2008.
24. Campbell J. Y., Lo A. W., MacKinlay A. C. The Econometrics of Financial Markets. — Princeton University Press, 1997.
25. Tsay R. S. Analysis of Financial Time Series. — 2-е изд. — John Wiley & Sons, 2005.
26. Багаев Э. И., Эшмаматова Д. Б. Модели ARIMA и методы сглаживания для анализа финансовых временных рядов // Замонавий математиканинг долзарб муаммолари ва татбиқлари. — Ташкент, 2026.

Приложения

ПРИЛОЖЕНИЕ А. Код модели LSTM

В данном приложении представлен программный код на языке Python, реализующий архитектуру рекуррентной нейронной сети долгой краткосрочной памяти (LSTM). Скрипт включает этапы загрузки данных, формирования временных последовательностей (скользящего окна), построения и обучения глубокой модели с использованием механизма ранней остановки, а также вычисления итоговых метрик качества.

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import random
5 import os
6 import warnings
7
8 import tensorflow as tf
9 from tensorflow.keras.models import Sequential
10 from tensorflow.keras.layers import LSTM, Dense
11 from tensorflow.keras.callbacks import EarlyStopping
12 from sklearn.preprocessing import MinMaxScaler
13 from sklearn.metrics import mean_absolute_error,
    mean_squared_error
14
15 warnings.filterwarnings("ignore")
16
17 SEED = 42
18 random.seed(SEED)
19 np.random.seed(SEED)
20 tf.random.set_seed(SEED)
21
22 # Загрузка данных
23 df = pd.read_csv("data/processed_data.csv")
24 df['date'] = pd.to_datetime(df['date'])
25 series = df['usd_uzs_scaled'].values
26
27 # Создание последовательностей
28 def create_sequences(data, window_size):
```

```

29     X, y = [], []
30     for i in range(len(data) - window_size):
31         X.append(data[i:i + window_size])
32         y.append(data[i + window_size])
33     return np.array(X), np.array(y)
34
35 WINDOW_SIZE = 10
36 X, y = create_sequences(series, WINDOW_SIZE)
37 X = X.reshape((X.shape[0], X.shape[1], 1))
38
39 # Train / Test
40 train_size = int(len(X) * 0.8)
41 X_train, X_test = X[:train_size], X[train_size:]
42 y_train, y_test = y[:train_size], y[train_size:]
43
44 # Построение модели
45 model = Sequential([
46     LSTM(50, input_shape=(X_train.shape[1], X_train.shape[2])),
47     Dense(1)
48 ])
49 model.compile(optimizer='adam', loss='mse')
50
51 # Обучение
52 early_stop = EarlyStopping(
53     monitor='val_loss', patience=5,
54     restore_best_weights=True
55 )
56 history = model.fit(
57     X_train, y_train, epochs=50, batch_size=32,
58     validation_split=0.1, callbacks=[early_stop], verbose=1
59 )
60
61 # Прогноз и обратная нормализация
62 predictions = model.predict(X_test)
63 df_scaler = pd.read_csv("data/processed_data.csv")
64 train_size_s = int(len(df_scaler) * 0.8)
65 scaler = MinMaxScaler()
66 scaler.fit(df_scaler[['usd_uzs']][:train_size_s])
67 predictions_real = scaler.inverse_transform(predictions)
68 y_test_real = scaler.inverse_transform(y_test.reshape(-1, 1))
69

```



```

70 # Метрики
71 mae = mean_absolute_error(y_test_real, predictions_real)
72 rmse = np.sqrt(mean_squared_error(y_test_real, predictions_real))
73 mape = np.mean(np.abs(
74     (y_test_real - predictions_real) / y_test_real
75 )) * 100
76 print(f"MAE: {mae:.2 f}, RMSE: {rmse:.2 f}, MAPE: {mape:.2 f}%")

```

ПРИЛОЖЕНИЕ Б. Код модели ARIMA (rolling forecast)

В данном приложении приведен исходный код, реализующий классическую статистическую модель ARIMA в режиме скользящего прогнозирования (rolling forecast). Код демонстрирует автоматический подбор гиперпараметров по информационному критерию Акаике (AIC) и алгоритм пошагового переобучения модели на каждом новом фактическом наблюдении.

```

1 import pandas as pd
2 import numpy as np
3 from statsmodels.tsa.arima.model import ARIMA
4 from pmdarima import auto_arima
5 from sklearn.metrics import mean_absolute_error,
   mean_squared_error
6
7 # Загрузка данных
8 df = pd.read_csv("data/processed_data.csv")
9 df['date'] = pd.to_datetime(df['date'])
10
11 # Train / Test (80 / 20)
12 train_size = int(len(df) * 0.8)
13 train_series = df['usd_uzs'][:train_size]
14 test_series = df['usd_uzs'][train_size:]
15
16 # Автоматический подбор порядка (p, d, q) по AIC
17 auto_model = auto_arima(
18     train_series, seasonal=False, stepwise=True,
19     information_criterion='aic', trace=True
20 )
21 best_order = auto_model.order
22 print(f"Лучший порядок ARIMA: {best_order}")
23
24 # Rolling forecast: на каждом шаге модель переобучается

```

```

25 # на истории , дополненной РЕАЛЬНЫМ значением
26 history = list(train_series)
27 predictions = []
28 for real_value in test_series:
29     model_fit = ARIMA(history , order=best_order).fit()
30     yhat = model_fit.forecast(steps=1)[0]
31     predictions.append(yhat)
32     history.append(real_value) # добавляем реальное значение ,
                                не прогноз
33
34 forecast = pd.Series(predictions , index=test_series.index)
35
36 # Метрики
37 mae = mean_absolute_error(test_series , forecast)
38 rmse = np.sqrt(mean_squared_error(test_series , forecast))
39 mape = np.mean(np.abs((test_series.values - forecast.values)
40                  / test_series.values)) * 100
41 print(f"MAE: {mae:.2 f} , RMSE: {rmse:.2 f} , MAPE: {mape:.2 f}%")

```

ПРИЛОЖЕНИЕ В. Код модели ARIMA (static, без переобучения)

Данное приложение содержит фрагмент программного кода, реализующий построение статического прогноза с помощью модели ARIMA. В отличие от метода скользящего окна, в данном скрипте алгоритм обучается строго один раз на тренировочной выборке и формирует многошаговый прогноз на весь тестовый период без обновления внутренних параметров.

```

1 import pandas as pd
2 import numpy as np
3 from statsmodels.tsa.arima.model import ARIMA
4 from sklearn.metrics import mean_absolute_error ,
    mean_squared_error
5
6 # Загрузка данных
7 df = pd.read_csv("data/processed_data.csv")
8 df['date'] = pd.to_datetime(df['date'])
9
10 # Train / Test (80 / 20)
11 train_size = int(len(df) * 0.8)
12 train_series = df['usd_uzs'][:train_size]
13 test_series = df['usd_uzs'][train_size:]

```

```

14
15 # Используется тот же порядок , что и в rolling forecast
16 best_order = (4, 1, 2)
17
18 # Модель обучается ОДИН раз на train
19 model_fit = ARIMA(train_series , order=best_order).fit()
20
21 # Прогноз сразу на весь тестовый период без ( обновления данных )
22 predictions = model_fit.forecast(steps=len(test_series))
23 forecast = pd.Series(predictions.values , index=test_series.index)
24
25 # Метрики
26 mae = mean_absolute_error(test_series , forecast)
27 rmse = np.sqrt(mean_squared_error(test_series , forecast))
28 mape = np.mean(np.abs((test_series.values - forecast.values)
29                 / test_series.values)) * 100
30 print(f"MAE: {mae:.2f} , RMSE: {rmse:.2f} , MAPE: {mape:.2f}%")

```

ПРИЛОЖЕНИЕ Г. Код модели Random Forest

В приложении представлен код обучения ансамблевой модели машинного обучения Random Forest. Скрипт включает процедуру выделения признакового пространства на основе исторических лагов, инициализацию ансамбля деревьев решений и последующую оценку точности полученного одношагового прогноза.

```

1 import pandas as pd
2 import numpy as np
3 from sklearn.ensemble import RandomForestRegressor
4 from sklearn.metrics import mean_absolute_error ,
   mean_squared_error
5
6 # Загрузка данных
7 df = pd.read_csv("data/processed_data.csv")
8 df['date'] = pd.to_datetime(df['date'])
9
10 # Признаки — лаги за 7 предыдущих дней
11 features = ['lag_1' , 'lag_2' , 'lag_3' , 'lag_4' , 'lag_5' , 'lag_6' , '
   lag_7']
12 X = df[features]
13 y = df['usd_uzs']

```

```

14
15 # Train / Test (80 / 20)
16 train_size = int(len(df) * 0.8)
17 X_train , X_test = X[:train_size] , X[train_size:]
18 y_train , y_test = y[:train_size] , y[train_size:]
19
20 # Обучениemodelи
21 model = RandomForestRegressor(n_estimators=100, random_state=42)
22 model.fit(X_train , y_train)
23
24 # Прогнозиспользует ( реальныелаги -> аналогшагового 1- прогноза)
25 predictions = model.predict(X_test)
26
27 # Метрики
28 mae = mean_absolute_error(y_test , predictions)
29 rmse = np.sqrt(mean_squared_error(y_test , predictions))
30 mape = np.mean(np.abs((y_test.values - predictions)
31                 / y_test.values)) * 100
32 print(f"MAE: {mae:.2 f} , RMSE: {rmse:.2 f} , MAPE: {mape:.2 f}%")

```

ПРИЛОЖЕНИЕ Д. Код предобработки данных

В данном приложении содержится скрипт предварительной обработки эмпирических данных для последующего обучения алгоритмов. В коде реализованы процедуры отсеечения исторического периода до либерализации валютного рынка, проверка на наличие пропусков, генерация лаговых признаков и минимаксное масштабирование (нормализация) значений временного ряда.

```

1 import pandas as pd
2 from sklearn.preprocessing import MinMaxScaler
3
4 # Загрузкаисходныхданных
5 df = pd.read_csv("data/USD_UZS_daily.csv")
6 df['date'] = pd.to_datetime(df['date'])
7 df = df.sort_values('date')
8
9 # Отсечениеданныхдолиберализациирынkasентябрь ( 2017)
10 df = df[df['date'] >= '2017-09-05']
11
12 # Проверкапропусковиудубликатов

```

```

13 print("Пропуски:\n", df.isna().sum())
14 print("Дубликаты:", df.duplicated().sum())
15
16 # Формирование лаговых признаков (1..7)
17 for lag in range(1, 8):
18     df[f'lag_{lag}'] = df['usd_uzs'].shift(lag)
19 df = df.dropna()
20
21 # Разделение и нормализация (scaler обучается только на train)
22 train_size = int(len(df) * 0.8)
23 train, test = df[:train_size], df[train_size:]
24 scaler = MinMaxScaler()
25 train_scaled = scaler.fit_transform(train[['usd_uzs']])
26 test_scaled = scaler.transform(test[['usd_uzs']])
27
28 df.to_csv("data/processed_data.csv", index=False)
29 print("Train_size:", len(train), "Test_size:", len(test))

```

ПРИЛОЖЕНИЕ Е. Код построения совмещённого графика моделей

Данное приложение включает скрипт на языке Python, предназначенный для агрегации полученных результатов прогнозирования. Код обеспечивает считывание сохранённых CSV-файлов и визуализацию траекторий всех исследуемых моделей поверх фактического графика валютного курса с использованием библиотеки Matplotlib.

```

1 import pandas as pd
2 import matplotlib.pyplot as plt
3 import matplotlib.dates as mdates
4
5 # Загрузка сохранённых прогнозов всех моделей
6 arima_roll = pd.read_csv('results/arima_forecast.csv',
7     parse_dates=['date'])
8 arima_stat = pd.read_csv('results/arima_static_forecast.csv',
9     parse_dates=['date'])
10 lstm = pd.read_csv('results/lstm_forecast.csv', parse_dates=['
11     date'])
12 rf = pd.read_csv('results/rf_forecast.csv', parse_dates=['date'
13 ])
14
15 fig, ax = plt.subplots(figsize=(14, 6))

```

```

12 ax.plot(arima_roll['date'], arima_roll['actual'], color='black',
13         linewidth=1.5, label='Реальный_курс', zorder=5)
14 ax.plot(arima_roll['date'], arima_roll['forecast'], label='ARIMA_
    (rolling)')
15 ax.plot(arima_stat['date'], arima_stat['forecast'], label='ARIMA_
    (static)')
16 ax.plot(lstm['date'], lstm['forecast'], label='LSTM')
17 ax.plot(rf['date'], rf['forecast'], label='Random_Forest')
18
19 ax.set_xlabel('Дата'); ax.set_ylabel('Курс_USD/UZS_сум()')
20 ax.set_title('Сравнение_прогнозов_всех_моделей_на_тестовой_выборке')
21 ax.legend(loc='upper_left'); ax.grid(True, alpha=0.3)
22 ax.xaxis.set_major_formatter(mdates.DateFormatter('%b_%Y'))
23 plt.xticks(rotation=45); plt.tight_layout()
24 plt.savefig('plots/plot_all_models.png', dpi=200, bbox_inches='
    tight')

```

Представленные в Приложениях А–Е фрагменты программного кода составляют основу вычислительной и практической реализации данного исследования. Разработанный комплекс скриптов образует полноценный аналитический пайплайн: от первичной загрузки и нормализации исторических данных до обучения нейросетевых архитектур и визуализации итоговых прогнозов. Полный исходный код проекта, а также использованные наборы данных доступны для детального ознакомления и полного воспроизведения проведенных экспериментов в открытом репозитории по адресу: <https://github.com/fuwe7/diploma>.