

Содержание

Введение	2
1 Теоретические основы прогнозирования финансовых временных рядов	5
1.1 Особенности финансовых временных рядов	5
1.2 Классические модели прогнозирования курса валют	7
1.3 Методы машинного обучения в прогнозировании	10
1.4 Нейросетевые модели прогнозирования	12
2 Методология исследования и описание данных	16
2.1 Выбор объекта исследования	16
2.2 Очистка и подготовка данных	19
2.3 Постановка задачи прогнозирования	21
2.4 Используемые модели	21
3 Практическая реализация (эксперименты и результаты)	22
3.1 Результаты обучений классических моделей	22
3.2 Результаты ML-моделей	22
3.3 Построение и обучение LSTM	22
3.4 Сравнение результатов всех моделей	22
3.5 Интерпретация результатов	22
Заключение	23
Приложения	24
А Приложение А. Код модели LSTM	24
Список литературы	24

Введение

Актуальность темы. Современные финансовые рынки характеризуются высокой степенью нестабильности, представляя собой сложную, хаотичную и высокодинамичную среду. В условиях глобализации и непрерывных изменений экономических тенденций прогнозирование валютных курсов приобретает особую значимость. Точные прогнозы жизненно необходимы для макроэкономического планирования, стабильной работы банковского сектора, инвестиционной деятельности и эффективного государственного управления. Однако данная задача осложнена беспрецедентно высокой волатильностью и неполнотой рыночной информации. В отличие от многих других сфер (например, прогнозирования спроса на электроэнергию, где известны четкие факторы — погода или календарные дни), понимание факторов, влияющих на курсы валют, сильно ограничено, а широко известные прогнозы могут сами по себе менять поведение участников торгов, делая валютные тенденции труднопредсказуемыми. Традиционные методы прогнозирования далеко не всегда дают точные результаты и не способны уловить все закономерности в условиях хаоса. В последние годы, чтобы решить эту проблему, активно развиваются и внедряются алгоритмы машинного обучения (ML) и глубокие нейросети, предлагая новый взгляд на анализ данных. В научной литературе сформировалось два основных лагеря в подходах к прогнозированию: использование классических статистических моделей и применение методов машинного обучения. Традиционно прогнозирование финансовых временных рядов осуществлялось с помощью классических моделей, флагманом среди которых является интегрированная модель авторегрессии и скользящего среднего (ARIMA). При всех своих плюсах, модели этого класса имеют существенное ограничение: они предполагают линейную форму взаимосвязей и зачастую постоянную дисперсию, из-за чего им трудно справляться с нелинейными рыночными паттернами.

С другой стороны, искусственные нейронные сети и методы глубокого обучения, такие как сети с долгой краткосрочной памятью (LSTM), обладают высочайшей гибкостью и мощным потенциалом для нелинейного моделирования. Архитектуры LSTM способны сохранять важную информацию из бо-

лее ранних периодов благодаря специальным механизмам памяти, что делает их крайне эффективными для временных рядов. Однако проблема заключается в том, что в научном сообществе до сих пор нет однозначного ответа, какой метод лучше. Не смотря на наличие большого количества исследований, результаты остаются противоречивыми: одни работы доказывают подавляющее превосходство нейросетей, тогда как другие указывают, что классические методы (особенно на определенных горизонтах планирования) или гибридные модели показывают не менее высокую, а порой и лучшую точность.

Цель работы. Целью данной работы является сравнение эффективности классических статистических моделей и нейросетевых методов при прогнозировании курса валют.

Задачи работы. Для достижения поставленной цели были сформулированы следующие задачи:

1. изучить особенности финансовых временных рядов;
2. рассмотреть классические модели прогнозирования;
3. изучить методы машинного обучения;
4. исследовать нейросетевые модели;
5. подготовить исторические данные для анализа;
6. обучить выбранные модели;
7. сравнить полученные результаты.

Объект исследования. Объектом исследования выступает валютный курс (на примере выбранной валютной пары, например, USD/UZS).

Предмет исследования. предметом исследования являются методы прогнозирования временных рядов.

Методы исследования. В процессе выполнения работы применяются следующие методы анализа и прогнозирования:

1. статистические методы (в частности, параметрические модели ARIMA);
2. методы машинного обучения (ML);
3. нейросетевые методы (включая архитектуру рекуррентных сетей LSTM).

Структура работы. Работа состоит из введения, трёх глав, заключения, списка литературы и приложений.

Глава 1. Теоретические основы прогнозирования финансовых временных рядов

1.1 Особенности финансовых временных рядов

Временным рядом (или рядом динамики) называется последовательность значений некоторого статистического показателя (случайной величины), упорядоченных в хронологическом порядке — в последовательные моменты или периоды времени. В экономике и финансах типичными примерами временных рядов выступают курсы обмена валют, котировки акций, уровень инфляции, показатели спроса и валовой национальный продукт. В зависимости от характера фиксации времени ряды могут быть дискретными и непрерывными. В непрерывных рядах значения переменной фиксируются непрерывно во времени, однако на практике (особенно в финансах) чаще всего анализируются дискретные временные ряды, где наблюдения производятся через определенные фиксированные интервалы времени (например, ежечасно, ежедневно, ежемесячно). Таким образом, временной ряд в контексте данной работы — это упорядоченная во времени последовательность исторических значений валютного курса.

В классическом анализе любой экономический временной ряд традиционно рассматривается как результат взаимодействия нескольких основных компонент:

- Тренд (тенденция) — плавно меняющаяся компонента, описывающая чистое влияние долговременных факторов и отражающая общую (вековую) тенденцию процесса к росту или снижению.
- Сезонность — регулярные колебания, отражающие внутригодовую или внутримесячную повторяемость экономических процессов.
- Цикличность — последовательность волнообразных флуктуаций (экономических циклов), длительность которых обычно превышает один год (например, циклы деловой активности).
- Случайная (нерегулярная) составляющая (шум) — непредсказуемые колебания, отражающие влияние множества не поддающихся учету слу-

чайных факторов.

Ключевым свойством, необходимым для анализа и моделирования, является стационарность временного ряда. Строго стационарным называется ряд, совместное распределение вероятностей которого не изменяется при сдвиге во времени. В практических исследованиях чаще опираются на понятие слабой стационарности: ряд считается стационарным, если его математическое ожидание (среднее значение) и дисперсия остаются постоянными во времени, а ковариация зависит только от временного лага.

Стационарность крайне важна, поскольку большинство классических статистических методов и теорем опираются на предположение о неизменности свойств процесса. Проблема заключается в том, что реальные финансовые ряды практически всегда нестационарны. Их среднее значение и дисперсия меняются с течением времени, формируя стохастические тренды. Для приведения таких рядов к стационарному виду обычно применяются математические преобразования, чаще всего — переход от абсолютных значений к их разностям (приращениям).

Финансовые временные ряды, в частности курсы валют, обладают ярко выраженной спецификой, которая значительно усложняет их математическое описание:

- Волатильность. Для финансовых рынков характерны резкие скачки и нестабильность дисперсии. Широко известен эффект «кластеризации волатильности»: периоды сильных и резких колебаний цены часто сменяются периодами относительного затишья.
- Нестационарность. Валютные курсы подвержены влиянию макроэкономических трендов и структурных изменений. Часто их поведение близко к процессу «случайного блуждания» (random walk), что делает их непредсказуемыми на больших горизонтах.
- Автокорреляция. Текущие значения финансовых показателей и их волатильность часто зависят от прошлых значений (наличие "памяти" у рынка), что фиксируется с помощью автокорреляционных функций.
- Нелинейность. Динамика финансовых рынков характеризуется высокой сложностью, а поведение участников рынка приводит к тому, что

изменения цен не описываются простыми линейными формулами.

- Шум и случайность. Финансовые показатели содержат значительную долю шума (соотношение сигнал/шум крайне низкое). На них ежеминутно влияют поступление новых случайных новостей, макроэкономическая статистика и политические события.

Специфические свойства финансовых временных рядов порождают серьезные трудности при их прогнозировании. Из-за беспрецедентно высокой неопределенности, динамизма и хаотичности финансовой среды предсказание курсов валют является задачей повышенной сложности. Традиционные статистические подходы и линейные модели (такие как ARIMA или экспоненциальное сглаживание), несмотря на их полезность, не всегда справляются с нелинейной природой и высокой зашумленностью финансовых данных. Это обуславливает необходимость использования более сложных и гибких аналитических инструментов.

Финансовые временные ряды представляют собой сложные, хаотичные и нестационарные структуры. Присущие им специфические свойства — высокая волатильность, нелинейность, подверженность случайным шокам и структурным сдвигам — требуют для анализа и точного прогнозирования применения современных продвинутых методов, в том числе алгоритмов машинного обучения и нейронных сетей.

1.2 Классические модели прогнозирования курса валют

Классические (статистические) методы прогнозирования основаны на математическом и статистическом анализе исторических данных временных рядов. На протяжении долгого времени они оставались основными и де-факто стандартными инструментами прогнозирования в экономике, финансах и бизнес-аналитике. Их доминирование было обусловлено хорошо проработанной теоретической базой и способностью выявлять базовые закономерности в данных задолго до появления современных вычислительных мощностей.

Самые простые подходы к прогнозированию опираются на методы усреднения прошлых наблюдений для выделения основной тенденции.

- Простое скользящее среднее (Moving Average): Идея этого метода заключается в вычислении среднего значения ряда за определенное фик-

сированное "окно" времени в прошлом. Это позволяет сгладить случайные колебания и шум в данных. Однако существенным минусом скользящего среднего является его запаздывание: прогнозы на основе этого метода всегда отстают от реальных изменений тренда.

- Экспоненциальное сглаживание: Данный метод решает проблему простого усреднения путем присвоения прошлым значениям различных весовых коэффициентов. Веса экспоненциально убывают по мере "старения" данных, благодаря чему наибольший вес придается самым последним наблюдениям. Это позволяет модели гораздо лучше и быстрее реагировать на недавние изменения курса.

Этот блок моделей формирует фундаментальную основу для анализа внутренней структуры временного ряда.

- AR (Autoregression — Авторегрессия): В моделях AR текущее значение переменной описывается как линейная зависимость от её собственных прошлых значений. Например, текущий курс валюты прогнозируется на основе курсов за вчерашний, позавчерашний и несколько предыдущих дней.
- MA (Moving Average — Скользящее среднее): В контексте статистического моделирования модель МА устанавливает зависимость текущего значения не от самих прошлых курсов, а от прошлых ошибок прогноза (случайных шоков или возмущений).
- ARMA (Autoregressive Moving Average): Представляет собой комбинацию авторегрессии (AR) и скользящего среднего (MA). Эта модель является базовой, но имеет жесткое ограничение: она корректно работает только для стационарных временных рядов.

Поскольку подавляющее большинство финансовых рядов нестационарны, центральной классической моделью стала ARIMA (Autoregressive Integrated Moving Average). Модель характеризуется тремя параметрами — ARIMA(p, d, q), где p и q отвечают за количество лагов AR и MA соответственно.

Ключевым нововведением является параметр дифференциации d (Integrated). Простым языком, чтобы применить модель к нестабильному (нестационар-

ному) курсу валют, алгоритм ARIMA сначала вычисляет разности между текущими и предыдущими значениями. Взятие разностей позволяет устранить тренд и сделать ряд стационарным. После этого к преобразованным данным применяется комбинация авторегрессии и анализа ошибок. Благодаря своей универсальности, ARIMA стала классическим стандартом прогнозирования в экономике и финансах.

Для учета дополнительных факторов классические модели были расширены:

- SARIMA: Данная модификация классической модели ARIMA учитывает сезонность. Она эффективна, если внутри временного ряда присутствуют регулярные циклические колебания (например, квартальные или месячные эффекты).
- ARIMAX: Позволяет включать в уравнение внешние независимые факторы (экзогенные переменные). Это дает возможность прогнозировать курс валюты не только по его собственной истории, но и с учетом внешних макроэкономических показателей.

Основными достоинствами классических статистических методов являются их простота и высокая интерпретируемость. Исследователь всегда может отследить логику модели и оценить статистическую значимость каждого коэффициента. Эти методы базируются на хорошо проверенной математической теории, что делает их результаты понятными и обоснованными.

Несмотря на статус рыночного стандарта, классические модели обладают существенными ограничениями. Главная проблема заключается в том, что они предполагают исключительно линейную форму взаимосвязи между переменными. В реальности же динамика валютных рынков имеет сложную нелинейную природу, которую эти модели не способны уловить. Кроме того, они строго требуют стационарности (или приведения к ней), обладают слабой способностью адаптироваться к сложным паттернам и структурным изменениям, что выливается в ограниченную точность прогнозирования в периоды рыночных шоков.

В связи с указанными ограничениями возникает объективная необходимость применения более современных методов анализа данных.

Классические статистические модели являются надежной базой для анализа временных рядов. Они прекрасно работают в относительно простых условиях и позволяют сделать глубокие аналитические выводы. Тем не менее, их строгие ограничения и неспособность обрабатывать сложную нелинейность финансовых рынков обуславливают необходимость перехода к передовым методам машинного обучения и нейронным сетям.

1.3 Методы машинного обучения в прогнозировании

Методы машинного обучения (ML) представляют собой подходы, позволяющие компьютерным моделям самостоятельно выявлять скрытые закономерности и извлекать знания непосредственно из «сырых» данных, без необходимости явного программирования жестких правил. В отличие от классических статистических моделей, алгоритмы машинного обучения не требуют строгих предварительных предположений (например, о нормальности распределения ошибок или линейности связей) и обладают способностью адаптировать свои параметры к сложным структурам в процессе обучения на исторических данных (обучающей выборке).

Применение методов машинного обучения к анализу временных рядов имеет принципиальную особенность: в своей базовой форме стандартные ML-алгоритмы не «понимают» природу времени, воспринимая набор данных как неупорядоченную совокупность независимых примеров. Для того чтобы алгоритм смог уловить динамику курса валют, данные необходимо специфическим образом преобразовать.

Чаще всего для этого используется метод скользящего окна, при котором создаются лаговые переменные (lags). В этом случае для прогнозирования текущего значения курса $y(t)$ в качестве входных признаков подаются его предыдущие исторические значения: $y(t-1)$, $y(t-2)$, $y(t-3)$ и так далее. Помимо этого, критически важными этапами становятся ручное конструирование признаков (feature engineering) и строгая нормализация данных, которая приводит значения к единому масштабу и обеспечивает корректную работу алгоритмов.

В современной аналитике используется ряд базовых и продвинутых ML-алгоритмов:

- Линейная регрессия. Простая параметрическая модель, предполагаю-

щая строгую линейную зависимость между входными лагами и прогнозируемым значением. Несмотря на свою ограниченность, она обладает прозрачной математической структурой и часто используется в качестве базового уровня (benchmark) для оценки качества более сложных методов.

- Деревья решений (Decision Trees). Непараметрический метод (например, алгоритм CART), который последовательно разбивает пространство входных признаков на набор непересекающихся областей с помощью простых логических условий. Деревья способны улавливать нелинейные зависимости, однако в чистом виде они весьма нестабильны и склонны к сильному переобучению.
- Случайный лес (Random Forest). Мощный ансамблевый метод, объединяющий множество независимых деревьев решений. Обучаясь на случайных подвыборках данных (bagging) и используя лишь случайное подмножество признаков для каждого разбиения, случайный лес декоррелирует деревья. Это значительно снижает общую дисперсию модели, повышает ее устойчивость к шуму и улучшает точность прогноза.
- Градиентный бустинг (Gradient Boosting). Еще один ансамблевый подход, в котором деревья строятся не независимо, а последовательно. Каждое новое дерево обучается на остатках (ошибках) предыдущего, тем самым алгоритм «медленно» и целенаправленно улучшает предсказательную способность. Современные реализации этого метода (например, XGBoost или LightGBM) обеспечивают высочайшую точность и крайне популярны в практических задачах.

Ключевым преимуществом методов машинного обучения является их способность эффективно выявлять и моделировать сложные нелинейные взаимосвязи между переменными. В отличие от классической эконометрики, ML-алгоритмы обладают высокой гибкостью, не требуют строгой стационарности ряда на этапе моделирования и демонстрируют значительно более высокую точность на больших массивах зашумленных данных.

Несмотря на высокую результативность, методы ML имеют ряд существенных ограничений. Во-первых, они сильно зависят от качества подготовки данных и конструирования признаков. Во-вторых, высокочемкие модели

(особенно деревья и ансамбли) подвержены высокому риску переобучения (overfitting), когда алгоритм просто запоминает шум вместо выявления истинных трендов. В-третьих, по мере роста сложности (от простых деревьев к ансамблям бустинга) значительно ухудшается интерпретируемость моделей: они превращаются в «черный ящик».

Однако главная проблема состоит в том, что традиционные методы ML не учитывают внутреннюю временную последовательность данных так же органично и глубоко, как это делают специализированные рекуррентные нейросети.

В сфере прогнозирования валютных курсов методы машинного обучения нашли широчайшее применение. Они внедряются в системы финансовой аналитики и алгоритмического трейдинга для оценки трендов и предсказания будущих котировок, поскольку способны учитывать как исторические ценовые данные, так и сложные перекрестные зависимости с другими финансовыми индикаторами.

Подводя итог, можно утверждать, что методы машинного обучения представляют собой гораздо более мощный и универсальный инструмент предсказания по сравнению с классическими статистическими моделями. Однако ограничения ML-моделей при работе со сложными последовательностями и их зависимость от ручного преобразования временных рядов обуславливают необходимость использования более совершенных инструментов. Это логически обуславливает необходимость перехода к современным нейросетевым моделям глубокого обучения, способным самостоятельно анализировать временной контекст.

1.4 Нейросетевые модели прогнозирования

Нейронные сети представляют собой вычислительные модели, способные выявлять сложные нелинейные зависимости в данных. Изначально концепция искусственных нейронных сетей была вдохновлена попытками исследователей математически описать процессы обработки информации в биологических нервных системах и мозге человека. Однако сегодня, в контексте практического машинного обучения и прогнозирования, они используются в первую очередь как эффективный инструмент статистического распознавания образов и мощный аппроксиматор функций. Главная ценность нейросе-

тей заключается в их способности самостоятельно извлекать скрытые правила и паттерны из «сырых» данных, решая задачи, с которыми традиционные алгоритмы не справляются.

В своей базовой форме архитектура нейронной сети состоит из нескольких слоев обработки информации. Традиционная структура включает:

- входной слой (принимает исходные данные);
- один или несколько скрытых слоев (выполняют основную вычислительную работу);
- выходной слой (выдает итоговый результат или прогноз).

Эти слои состоят из множества узлов (искусственных нейронов). Нейроны соседних слоев соединены между собой связями, каждая из которых имеет свой вес — числовой параметр, определяющий силу влияния одного узла на другой. Кроме того, каждый нейрон в скрытых слоях использует функцию активации — специальное математическое преобразование, которое добавляет в систему нелинейность. Именно наличие функции активации позволяет нейронной сети строить сложные кривые и улавливать нелинейные эффекты, а не просто сводиться к простой линейной модели.

Обучение нейронной сети — это итеративный процесс, при котором сеть подбирает оптимальные веса для минимизации ошибки. Для оценки качества работы сети используется функция потерь (ошибка), измеряющая разницу между предсказанием модели и фактическим значением. Обучение осуществляется с помощью алгоритма обратного распространения ошибки (backpropagation). Суть алгоритма в том, что он вычисляет долю ответственности каждого параметра за итоговую ошибку и передает этот сигнал ошибки в обратном направлении — от выходного слоя к входному, последовательно корректируя веса так, чтобы на следующем шаге прогноз стал точнее.

Благодаря своей высокой гибкости нейросети стали применяться для анализа финансовых временных рядов. Они способны эффективно учитывать сложнейшие перекрестные зависимости, работать с зашумленными нелинейными данными и адаптироваться к изменяющимся условиям рынка. Однако обычные сети прямого распространения имеют существенный недостаток: они обрабатывают каждый пример изолированно и плохо учитывают са-

му хронологическую последовательность данных (отсутствие "памяти"), что критично для временных рядов.

Для того чтобы сеть могла улавливать временную динамику, были разработаны рекуррентные нейронные сети (RNN). В отличие от сетей прямого распространения, архитектура RNN содержит обратные связи (циклы), что позволяет им сохранять информацию о прошлых состояниях и использовать предыдущие значения для прогнозирования текущих. Это делает их естественно приспособленными для работы со временем.

Ключевая проблема стандартных RNN заключается в так называемом «затухании градиентов» (vanishing gradients). При попытке обучить сеть улавливать зависимости между событиями, далеко разнесенными во времени, сигнал ошибки экспоненциально уменьшается в процессе обратного распространения, из-за чего сеть на практике способна «помнить» лишь небольшое количество последних шагов.

Сеть с долгой краткосрочной памятью (Long Short-Term Memory, LSTM) представляет собой глубоко улучшенную версию RNN, специально спроектированную для решения проблемы затухающих градиентов. Эта архитектура умеет стабильно «запоминать» долгосрочные зависимости на протяжении больших отрезков времени. За счет поддержания постоянного потока ошибки во времени, LSTM успешно обходит ограничения простых RNN. На сегодняшний день она является одной из самых мощных моделей для работы со сложными временными рядами, включая финансовые котировки. Успех LSTM основан на том, что вместо обычных скрытых узлов в ней используются сложные «ячейки памяти». Поток информации в этих ячейках контролируется через три типа шлюзов («ворот»). Входные ворота (input gate) решают, какую новую информацию стоит добавить в память; забывающие ворота (forget gate) определяют, какую устаревшую и ненужную информацию пора стереть; а выходные ворота (output gate) контролируют, какая часть информации из ячейки будет использована для текущего прогноза. Такая логика позволяет сети избирательно управлять своей памятью.

К главным преимуществам нейросетевых моделей (и LSTM в частности) относятся:

- высочайшая точность прогнозирования при наличии достаточного объема данных;

- способность органично работать с сильной нелинейностью;
- автоматическое выявление сложнейших и неочевидных скрытых зависимостей без необходимости вручную задавать математическую формулу связи.

Тем не менее, применение нейросетей сопряжено с серьезными трудностями:

- высокая архитектурная и вычислительная сложность;
- алгоритмы требуют очень больших объемов размеченных исторических данных;
- модели долго обучаются и подвержены риску переобучения (overfitting);
- нейросети являются «чёрным ящиком»: их внутреннюю логику и причины конкретного предсказания практически невозможно интерпретировать.

Несмотря на перечисленные ограничения, глубокие нейросети, особенно архитектура LSTM, активно используются в финансах. Они дают отличные практические результаты в банковском секторе и биржевой аналитике, являясь передовым инструментом для прогнозирования сложных и волатильных валютных рядов, динамику которых не могут объяснить классические эконометрические методы.

Нейронные сети, и в особенности рекуррентные сети, представляют собой чрезвычайно мощный инструмент для анализа данных. Учитывая специфику финансовых рынков, модель LSTM является наиболее подходящей и эффективной среди нейросетевых архитектур для поставленной задачи. Именно эта модель будет использоваться в практической части дипломной работы для сравнения с классическими статистическими методами.

Глава 2. Методология исследования и описание данных

2.1 Выбор объекта исследования

В качестве объекта исследования в данной дипломной работе выбран официальный курс доллара США к узбекскому суму (валютная пара USD/UZS) за период с 1 января 2015 года по сентябрь 2025 года. Данный показатель представляет собой классический финансовый временной ряд исторических значений валютного курса, строго упорядоченных в хронологической последовательности. Прогнозирование именно этой финансовой метрики является центральной прикладной задачей для последующего применения и сравнения классических статистических алгоритмов и методов глубокого обучения.

Выбор курса USD/UZS в качестве основного объекта моделирования обусловлен высокой макроэкономической значимостью данного валютного курса для экономики Республики Узбекистан. Доллар США традиционно выступает ключевой резервной, инвестиционной и расчетной валютой. В условиях открытой экономики динамика курса доллара оказывает прямое и масштабное влияние на уровень внутренней инфляции, стоимость потребительской корзины, конкурентоспособность национального экспорта и объемы импортных операций. Точный прогноз данного показателя широко используется и крайне востребован в банковской сфере, государственном макроэкономическом планировании, корпоративном секторе и инвестиционном анализе для минимизации валютных рисков. Кроме того, выбор подкреплен наличием обширных, регулярно фиксируемых исторических данных, что является обязательным требованием для качественного и глубокого обучения нейросетевых моделей.

Критически важным аспектом любого математического и нейросетевого моделирования является использование достоверных, точных и согласованных эмпирических данных. В рамках данного исследования исторические данные получены из открытых официальных источников — базы данных Центрального банка Республики Узбекистан. Использование официального курса гарантирует высокую степень надежности исходной информации. Выгруженный массив данных представлен в универсальном табличном формате CSV (Comma-Separated Values), который является стандартом для хра-

нения структурированных данных и позволяет осуществлять быструю программную обработку (импорт, парсинг и очистку) средствами языков программирования (например, Python) на последующих этапах работы. Полный набор данных, использованных в исследовании, доступен в электронном виде в репозитории: <https://github.com/fuwe7/diploma>.

Сформированный исходный набор данных представляет собой дискретный одномерный временной ряд ежедневной частоты фиксации. Общая выборка охватывает 4018 последовательных наблюдений (календарных дней). Важнейшей позитивной характеристикой данного временного ряда является его строгая упорядоченность по времени и полное отсутствие пропусков (missing values) на всем рассматриваемом интервале. Это обстоятельство позволяет избежать применения искусственных методов интерполяции данных, которые потенциально могли бы исказить дисперсию ряда, внести нежелательный статистический шум в обучающую выборку и тем самым снизить объективность сравнения моделей.

Для первичного визуального анализа динамики валютной пары был построен линейный график исторического временного ряда.




Рис. 2.1: Динамика курса доллара США к узбекскому суму за 2015–2025 гг.

На представленном рисунке наглядно отображена траектория изменения курса доллара США к узбекскому суму. В целом, временной ряд имеет ярко выраженный долгосрочный восходящий тренд (девальвационная динамика национальной валюты), на который накладываются периоды локальной

стабилизации и стохастических колебаний. Однако при анализе графика особое внимание привлекает одна критическая аномалия — беспрецедентно резкий структурный скачок (изменение базового уровня курса), произошедший в начале сентября 2017 года. В этот короткий промежуток времени номинальное значение курса одномоментно выросло почти в два раза: с отметки около 4210 сумов до 8100 сумов за один доллар США.

Наличие столь радикального структурного сдвига на графике объясняется фундаментальными изменениями в экономике — проведением масштабной либерализации валютной политики и переходом Республики Узбекистан к рыночному механизму формирования курса (свободному плаванию). С точки зрения математической статистики и эконометрики, одним из важнейших условий сопоставимости уровней временного ряда является однородность этапов, в пределах которых исследуемый показатель подчиняется единому закону развития. В статистическом анализе для этого применяется исторический метод периодизации, согласно которому ряд необходимо разделять на однокачественные периоды на основе дат кардинальной смены хозяйственного механизма или принятия важнейших управленческих решений.

Если проводить обучение классических моделей и нейронных сетей на всем массиве данных с 2015 года, алгоритмы столкнутся с экстремальной неоднородностью (гетерогенностью) обучающей выборки. Модели будут пытаться математически аппроксимировать этот нерыночный структурный разрыв, что неизбежно приведет к смещению весов, искажению параметров тренда и критическому падению точности предсказаний на современном этапе. В связи с этим дальнейший анализ, стандартизация данных и непосредственное обучение моделей будут проводиться исключительно на однородной части массива — на данных, начиная с сентября 2017 года, когда сформировался современный рыночный режим валютного ценообразования.

Таким образом, выбранный объект исследования обладает высокой актуальностью, а имеющиеся исторические данные достоверны и репрезентативны. Обоснованное отсечение неоднородного исторического периода до валютной либерализации 2017 года обеспечивает необходимую статистическую однородность выборки. Это создает надежную и корректную базу данных, которая является полностью достаточной для построения, обучения и объективного сравнения эффективности классических статистических моде-

лей и передовых нейросетевых архитектур прогнозирования.

2.2 Очистка и подготовка данных

Перед построением моделей прогнозирования исходные данные были подвергнуты процедурам очистки и предварительной обработки. Целью данного этапа является обеспечение корректности и сопоставимости данных, а также подготовка их к использованию в различных моделях прогнозирования. Как отмечается в эконометрической литературе, точность любого прогноза строго ограничивается достоверностью и качеством тех данных, на которых он построен.

На первом этапе была проведена проверка исходного набора данных на наличие пропущенных значений (*missing values*) и дубликатов. В ходе анализа установлено, что пропуски отсутствуют, а временной ряд является непрерывным и корректно упорядоченным по времени. Это полностью удовлетворяет базовым требованиям, предъявляемым к эмпирическим данным для статистического анализа и прогнозирования.

Одним из важнейших условий сопоставимости уровней интервального ряда является однородность этапов, в пределах которых показатель подчиняется единому закону развития. В связи с выявленным структурным разрывом временного ряда, обусловленным масштабной либерализацией валютного рынка в 2017 году, из дальнейшего анализа был исключен период до сентября 2017 года. Сохранение данных до этого структурного сдвига неизбежно привело бы к смещению оценок и искажению параметров обучаемых алгоритмов.

Для объективной оценки качества моделей данные были разделены на обучающую (*train*) и тестовую (*test*) выборки в соотношении 80/20. Поскольку тестовые данные применяются исключительно для независимой оценки предсказательной способности (генерализации) и не участвуют в подборе параметров, это позволяет получить достоверное представление о том, как модель будет вести себя на новых данных. Разделение производилось строго с учетом временной структуры данных без случайного перемешивания наблюдений (с параметром *shuffle=False*). Во временных рядах случайное перемешивание недопустимо, так как оно разрушает автокорреляционную структуру и хронологическую зависимость наблюдений.

После предварительной обработки данные были разделены на обучающую и тестовую выборки. Для обеспечения корректной работы моделей машинного обучения и нейросетевых архитектур была выполнена нормализация данных с использованием метода Min-Max масштабирования. Нейронные сети высокочувствительны к масштабу входных значений: приведение данных к единому диапазону (от 0 до 1) существенно ускоряет сходимость алгоритмов оптимизации и предотвращает доминирование признаков с изначально большими числовыми значениями. Процесс масштабирования инициализируется следующим образом:

```
1 scaler = MinMaxScaler()
```

Критически важно отметить, что адаптация параметров масштабирования (поиск минимума и максимума) выполнялась только на обучающей выборке. Тестовая выборка трансформировалась на основе параметров, полученных из обучающей. Это строгое методическое правило необходимо для предотвращения так называемой «утечки данных» (data leakage) — недопустимого попадания информации из будущего тестового периода в процесс обучения модели.

Стандартные алгоритмы машинного обучения по умолчанию не воспринимают хронологический порядок, поэтому временной контекст необходимо задавать явно через конструирование признаков (feature engineering). Для учета временной зависимости значений временного ряда были сформированы лаговые признаки, представляющие собой значения курса за предыдущие моменты времени. В частности, были использованы значения курса за несколько предыдущих дней (лаговые переменные). Лаги формировались на основе уже нормализованных значений путем сдвига временного ряда назад, что в программной среде реализуется следующим образом:

```
1 for lag in range(1, 7):  
2     df[f'lag_{lag}'] = df['usd_uzs'].shift(lag)
```

Создание лагов позволяет регрессионным алгоритмам выявлять автокорреляционные зависимости и предсказывать текущее значение на основе недавней исторической памяти рынка.

В результате формирования лаговых признаков (из-за смещения значений) в самом начале временного ряда закономерно возникли пропущенные значения (NaN). Поскольку большинство моделей машинного обучения

не способно обрабатывать векторы с отсутствующими данными, эти пустые строки были удалены из выборки.

Подготовленный набор данных был сохранён в отдельный файл для дальнейшего использования, что гарантирует воспроизводимость экспериментов на различных этапах моделирования:

```
1 full.to_csv('prepared_data.csv', index=False)
```

Специфика применяемых в работе алгоритмов требует различного формата представления входных переменных. Подготовка данных осуществлялась с учетом архитектурных особенностей используемых моделей: Для классических статистических моделей (ARIMA) использовался исходный (непреобразованный) временной ряд, так как авторегрессионные компоненты формируются и дифференцируются внутри самой математической модели. Для моделей машинного обучения (ML) использовались сформированные лаговые признаки в виде традиционной двумерной матрицы «объект-признак». Для нейросетевых моделей (LSTM) формировались специфические последовательности наблюдений в виде трехмерных тензоров, что является обязательным требованием для рекуррентных слоев, обрабатывающих хронологию и внутренние состояния.

Таким образом, исходные данные были очищены, преобразованы и подготовлены для дальнейшего применения различных методов прогнозирования, что обеспечивает корректность, математическую обоснованность и сопоставимость результатов в ходе последующего моделирования.

2.3 Постановка задачи прогнозирования

2.4 Используемые модели

Глава 3. Практическая реализация (эксперименты и результаты)

3.1 Результаты обучений классических моделей

3.2 Результаты ML-моделей

3.3 Построение и обучение LSTM

3.4 Сравнение результатов всех моделей

3.5 Интерпретация результатов

Заключение

Приложения

A Приложение A. Код модели LSTM