
Сравнение эффективности нейросетей и классических статистических моделей в прогнозировании курса валют

Выпускная квалификационная работа

Багаев Эмир | Группа: МИ-1

Научный руководитель: Эшмаматова Д. Б.

2026 г.

Теория и методология

1. Актуальность и цели работы
2. Исследуемые модели
3. Данные и предобработка
4. Математический аппарат

Эксперименты и выводы

5. Результаты моделей
6. Rolling vs Static ARIMA
7. Ключевые выводы

Актуальность, цель и задачи

! Актуальность

Прогнозирование валютных курсов — ключевая задача для банков, инвесторов и госуправления. Финансовые ряды **нестационарны, нелинейны** и содержат высокий уровень шума. В литературе *нет консенсуса*: превосходят ли нейросети классические модели.

Цель работы:

Сравнить эффективность классических статистических моделей и нейросетевых методов при прогнозировании курса USD/UZS.

Задачи:

- Изучить теорию временных рядов
- Реализовать ARIMA, Random Forest, LSTM
- Провести эксперименты на данных ЦБ РУз
- Сравнить модели по MAE, RMSE, MAPE

ARIMA

- Классическая статистическая модель
- Авторегрессия + скользящее среднее
- Дифференциация для стационарности
- Два режима: rolling и static

Random Forest

- Ансамбль деревьев решений
- Bagging + случайные признаки
- Устойчивость к шуму
- Лаговые признаки на входе

LSTM

- Рекуррентная нейросеть
- Шлюзы: forget, input, output
- Долгосрочная память
- 50 нейронов, окно = 10 дней

Ключевой вопрос: способны ли нейросети с нелинейным моделированием превзойти проверенные временем статистические методы на реальных данных курса USD/UZS?

Данные и предобработка

Набор данных

- **Источник:** ЦБ Республики Узбекистан
- **Пара:** USD/UZS (официальный курс)
- **Период:** сентябрь 2017 — сентябрь 2025
- **Объём:** 2087 наблюдений (рабочие дни)
- **Пропуски:** отсутствуют

Предобработка

- Отсечение данных до 2017 г. (либерализация рынка)
- MinMax-нормализация $[0, 1]$
- Формирование лаговых признаков
- Разделение: 80% train / 20% test
- Хронологический порядок (без перемешивания)

Почему с 2017 г.? До либерализации курс фиксировался административно. Включение этих данных внесло бы структурный сдвиг, искажающий обучение моделей.

Математический аппарат

= ARIMA(p, d, q)

$$w_t = c + \sum_{i=1}^p \phi_i w_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t$$

$w_t = \Delta^d y_t$ — дифференцированный ряд

ϕ_i — коэффициенты авторегрессии

θ_j — коэффициенты скользящего среднего

ε_t — белый шум

 Шлюзы LSTM

Forget: $f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$

Input: $i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$

Cell: $C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$

Output: $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$

$h_t = o_t \odot \tanh(C_t)$

Метрики оценки: $MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$ $RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$ $MAPE = \frac{1}{n} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%$


Результаты экспериментов

Модель	MAE (сум)	RMSE (сум)	MAPE (%)
<i>С переобучением (rolling forecast)</i>			
ARIMA (rolling)	19,05	28,55	0,15
<i>Без переобучения (однократное обучение)</i>			
LSTM	40,74	54,37	0,33
Random Forest	112,01	146,64	0,88
ARIMA (static)	235,35	305,23	1,89


LSTM — лидер среди моделей с однократным обучением: MAPE всего 0,33%.

ARIMA (static) без переобучения показывает MAPE 1,89% — в 12 раз хуже rolling forecast.

ARIMA (static)



LSTM



Наблюдение: LSTM точно следует за реальным курсом, тогда как статическая ARIMA сходится к линейному тренду.

Почему ARIMA (rolling) обгоняет всех?

Rolling Forecast

На каждом шаге t :

- Добавляет **фактическое** y_t в обучающую выборку
- Переобучает модель заново
- Прогнозирует $\hat{y}_{t+1}$

Результат: MAPE = **0,15%**

Модель всегда «видит» вчерашний курс

Static (без переобучения)

- Обучается **один раз** на train
- Прогнозирует весь test без обновления
- Прогноз сходится к линейному тренду

Результат: MAPE = **1,89%**

В 12 раз хуже rolling

Вывод: ARIMA (rolling) побеждает *не благодаря модели*, а благодаря **методологии переобучения**. При равных условиях (однократное обучение) **LSTM** превосходит и RF, и ARIMA — MAPE 0,33% vs 0,88% и 1,89%.

Ключевые выводы

- 1 **LSTM — лидер при честном сравнении.** В условиях однократного обучения нейросеть LSTM ($\text{MAPE} = 0,33\%$) значительно превосходит Random Forest ($0,88\%$) и статическую ARIMA ($1,89\%$).
- 2 **Rolling forecast — мощный, но методологически особый.** ARIMA с rolling forecast ($\text{MAPE} = 0,15\%$) показывает наименьшие ошибки, однако это преимущество обусловлено постоянным переобучением, а не качеством самой модели.
- 3 **Нейросети лучше улавливают нелинейность.** LSTM способна обучиться сложным паттернам валютного ряда, тогда как статическая ARIMA теряет точность уже на среднесрочном горизонте.
- 4 **Random Forest уступает обоим подходам.** Несмотря на устойчивость к шуму, ансамблевый метод не смог эффективно моделировать автокорреляционную структуру ряда USD/UZS.
- 5 **Практический вывод.** Для оперативного прогнозирования с обновлением данных оптимальна ARIMA (rolling). Для автономных прогнозов без переобучения — LSTM.
- 6 **Теоретическое обоснование.** Результаты подтверждены в тезисе «Модели ARIMA и методы сглаживания для анализа финансовых временных рядов» (Актуальные проблемы и приложения современной математики, Ташкент-2026), где формально показано условие стационарности авторегрессионной части и обоснован выбор ARIMA для моделирования нестационарных финансовых рядов.

Спасибо за внимание!

Сравнение эффективности нейросетей и классических статистических моделей в прогнозировании курса валют

Багаев Эмир | МИ-1

Главный вывод: При честном сравнении (однократное обучение) **LSTM** превосходит классические модели — MAPE 0,33% vs 0,88% (RF) vs 1,89% (ARIMA static)